



INSTITUT NATIONAL DE STATISTIQUE ET
D'ÉCONOMIE APPLIQUÉE

FONDS DE SOLIDARITÉ CONTRE LES ÉVÉNEMENTS
CATASTROPHIQUES (FSEC).

Etude de l'impact des changements climatiques sur les ressources en eau au niveau du bassin versant de la Moulouya

Etudiant :
LOUALID DALAL

Encadré par :
OULIDI Abderrahim
OUMECHTAQ Ismail

Année universitaire : 2022-2023

Résumé

Ce document est la synthèse de notre travail au sein de FSEC, qui fait partie de notre cursus d'Ingénieur d'État, le but est d'appliquer toutes les connaissances acquises dans notre cursus.

L'objectif principal du projet est d'exploiter des données des précipitations afin de les traiter et les analyser pour segmenter le bassin à des stations semblables, analyser les tendances et les ruptures et se projeter dans le futur. En utilisant la Visualisation, la classification, les tests statistiques et les séries chronologiques...

Afin de procéder à la réalisation des différentes tâches du projet, l'utilisation de ces outils est cruciale :

- **Langages de programmation** : PYTHON (L'un des meilleurs langages de programmation pour les projets/applications de data science), et R (le langage le plus classique destiné aux statistiques et à la science des données).
- **Environnement de programmation destiné** : GOOGLE COLABORATORY (pour le service cloud), ANACONDA (Distribution assurant la programmation en mode local) et Rstudio.

Remerciements

Dalal

Avant toute chose, je tiens à remercier Dieu, source de toute connaissance, savoir et volonté qui m'ont servi pour accomplir ce travail.

Au terme de ce travail, je tiens à remercier et à témoigner toute ma reconnaissance à toute personne ayant contribué de près ou de loin au bon déroulement de mon stage d'application et à l'élaboration de ce modeste travail.

Mes plus vifs remerciements s'adressent à toute l'équipe pédagogique du département Statistique Démographie, plus précisément au cadre professoral et administratif de L'IN-SEA, pour leur dévouement, leur qualité de formation, leurs efforts continus, leurs conseils prodigués ainsi que leur assistance tout au long de ma formation.

Mes sincères remerciements vont particulièrement à mon encadrant, OULIDI Abderrahim, d'avoir examiné et évalué ce travail, ainsi que pour leurs orientations critiques qui m'ont guidé et qui m'ont été grandement utiles dans la validation de l'ensemble des tâches. Je leur témoigne ma profonde gratitude. En dernier lieu, je ne peux achever sans exprimer ma profonde gratitude envers ceux qui ont toujours été là pour moi. J'adresse toutes mes affections à ma famille, particulièrement mes parents et mes sœurs qui ont contribué fortement à ma réussite, grâce à leurs encouragements, conseils et leurs sacrifices.

Table des matières

1	Introduction générale	8
1.1	Description générale du bassin	8
1.2	Changement climatique	10
2	Traitement des données	12
2.1	Construction de la base de données	12
2.1.1	Les étapes :	12
2.1.2	Choix sur la période d'étude :	13
2.1.3	Choix sur les stations d'étude :	14
2.1.4	La base de données finale non imputée :	18
2.2	Imputation de données manquantes	19
2.2.1	Généralités sur l'imputation	19
2.2.2	Les principales méthodes d'imputations	20
2.2.3	Analyse de la performance et validation de la méthode choisie	22
2.2.4	Base de données finale imputée avec la méthode MissForest.	25
2.3	Visualisations.	25
2.3.1	les boites à moustaches par mois	25
2.3.2	les boites à moustaches par an.	26
2.4	Statistique descriptive	27
2.4.1	Approche classique	27
2.4.2	Approche saisonnière	28
2.5	Segmentation de la zone d'étude	31
2.5.1	Introduction	31
2.5.2	Mesures de distance	32
2.5.3	Segmentation hiérarchique	33
2.5.4	Résultats	34
3	Détection du changement climatique	41
3.1	Analyse des tendances	41
3.1.1	Tests classiques utilisés	41
3.1.2	Résultats	42
3.2	Analyse des ruptures	43
3.2.1	Tests classiques utilisés	44
3.2.2	Résultats	45
3.3	Analyse des projections future	47
3.3.1	L'évolution des précipitations durant toute la période en faisant la moyenne et la variance sur chaque année	48
3.3.2	surapprentissage	49

3.3.3	Définition de la non stationnarité	51
3.3.4	Test de stationnarité	51
3.3.5	Dickey-Fuller augmenté	52
3.3.6	Application sur les séries chronologiques :	52
3.3.7	Autocorrélation	53
3.3.8	Prédictions	57
3.4	Ouverture sur une autre analyse :	59
4	Conclusion	61
A	Lien du pdf de l'annexe	62

Table des figures

1.1	Les provinces du bassin hydraulique de la Moulouya	9
1.2	Carte des précipitations moyennes dans le bassin hydraulique de la Moulouya	10
2.2	Base de données de ABHM	12
2.1	Base de données de la DGM	13
2.3	Extrait du pourcentage des valeurs manquantes par date	14
2.4	Pourcentage des valeurs manquantes pour les 59 stations	16
2.5	Description statistique du pourcentage des NA pour les différentes stations	17
2.6	Box-plot du pourcentage des NA pour les différentes stations	17
2.7	Extrait de la base de données finale avant imputation	18
2.8	Plot of imputation method versus mean NRMSE	24
2.9	Extrait de la base de données finale après imputation	25
2.10	visualisation dynamique des précipitations dans toutes les stations en fonction du temps (voir Jupyter Notebook)	25
2.11	Les précipitations moyennes en ordre pour la saison d'hiver	29
2.12	Les précipitations moyennes en ordre pour la saison de printemps	29
2.13	Les précipitations moyennes en ordre pour la saison d'été	30
2.14	Les précipitations moyennes en ordre pour la saison d'automne	30
2.15	Dendogramme de la base de données	35
2.16	Classification de 6 groupes	36
2.17	Scatter plot	36
2.18	Extrait des données du groupe 1 avec min et max	37
2.19	Extrait des données du groupe 2 avec min et max	38
2.20	Extrait des données du groupe 3 avec min et max	38
2.21	Extrait des données du groupe 4 avec min et max	39
2.22	Extrait des données du groupe 5 avec min et max	39
2.23	Extrait des données du groupe 6 avec min et max	40
3.1	précipitation extrême en octobre 2008	47
3.2	précipitation extrême en mars 2004	47
3.3	Extrait des données d'entraînement	50
3.4	Extrait des données de test	50
3.5	Les coefficients du modèle ARMA,TLAT.AZLEF	56
3.6	Les coefficients du modèle ARMA, DAR.DRIOUCH	56
3.7	les coefficients de corrélation en utilisant la méthode de Pearson	59
3.8	Matrice de corrélation entre les précipitations des stations d'étude	60

Liste des tableaux

2.1	Nombre de stations à garder en fonction du pourcentage accepté des NA .	16
2.2	Caractéristiques des méthodes d'imputation de données manquantes utilisées	21
2.3	Moyenne NRMSE pour les différents pourcentages des valeurs manquantes	24
2.4	Analyse statistique des précipitations par saison et par station	31
2.5	Stations par groupe	37
3.1	Résultats Test Mann-Mendall	43
3.2	Résultats du test de Pettitt	46

Chapitre 1

Introduction générale

1.1 Description générale du bassin

Caractéristiques du bassin

Le bassin hydraulique de Moulouya se trouve dans la partie nord-est du pays et s'étend sur une superficie de 74.000 km² (soit 10% du territoire marocain). La zone du bassin hydraulique de la Moulouya couvre quasi-totalement la région administrative de l'Oriental (provinces de Nador, Figuig, Jrada, préfecture d'Oujda-Angad, Berkane-Taourirt). Elle couvre aussi partiellement les régions de Meknès-Tafilalet (province de Khénifra), Taza-Al Hoceima-Taounate (province de Taza) et Fès Boulemane (province de Boulemane).

Le bassin hydrologique de Moulouya couvre la grande majorité de la zone d'étude (55.500 km²). Les autres sous bassins incluent le bassin du Kert dans la province de Nador, Isly, Kiss (frontière entre le Maroc et l'Algérie), Chott Tigri, et une partie de la zone Bouarfa-Figuig (Haut Atlas Oriental).

Sur le plan morphologique, la Moulouya parcourt dès l'amont des zones de plaine sur une longue distance, alors que les zones de montagne fournissent l'eau et les sédiments par l'intermédiaire de ses nombreux affluents (Snoussi, 1980). Du sud vers le nord le bassin versant de la Moulouya comprend trois sous-bassins subdivisés suite à plusieurs accidents géologiques : la Haute, la Moyenne et la Basse Moulouya, ce dernier sous-bassin constitue la zone de notre étude. Le long de son cours moyen, cette rivière reçoit pratiquement toutes les eaux du versant sud-est du Moyen Atlas plissé, son principal affluent moyen-atlas (de rive gauche) étant l'oued Melloulou. À ce niveau, les versants arides de la rive droite de la Moulouya sont drainés par des petits cours d'eau éphémères. En allant vers le Nord, la Moulouya reçoit l'oued Msoun, qui collecte les eaux des reliefs sud-est du Rif Oriental, avant de confluer avec l'oued Za, un des plus larges réseaux des plateaux arides de l'Oriental marocain, et draine tout le bassin versant jusqu'à son embouchure sur la méditerranée.




FIGURE 1.1 – Les provinces du bassin hydraulique de la Moulouya

Climat

Le bassin de la Moulouya, présente une large gamme d'étages bioclimatiques. Dans son bassin supérieur, aux confins du haut Atlas, où l'oued prend sa source, et dans ses affluents principaux de rive gauche drainant le Moyen Atlas, le climat humide, à hiver frais et neigeux, génère des précipitations importantes et généralement régulières (600 à 900 mm/an) (ABHM 2008)

En moyenne et basse Moulouya, les conditions climatiques tendent vers un climat semi-aride à aride, où les précipitations sont sporadiques et d'importance très inégale (de 190 à 500 mm/an) (Boumeaza et al., 2010). En effet, situé en marge sud-ouest de la Méditerranée, le nord-Est du Maroc se caractérise par un climat typiquement méditerranéen. Les perturbations atlantiques constituent la principale origine des masses d'air humides dans le Rif, les montagnes rifaines constituent un obstacle qui abrite le bassin de la basse Moulouya des perturbations provenant de l'Atlantique, en plus des perturbations méditerranéennes (liées à l'arrivée des masses d'air froides du Nord), qui sont moins fréquentes, mais généralement plus humides.

L'influence des pressions sahariennes est aussi non négligeable, ces pressions sont à l'origine du chergui et du sirocco, vents chauds et secs du Sud et du Sud-Est. En effet, le Cap des Trois Fourches et les monts Gourougou et Bni Bou Ifrou, alignés selon une direction Nord-Sud sur la bordure Nord-Ouest de la région Nord-Orientale, constituent un obstacle à ces perturbations, alors que les monts Kbdana, plus à l'est, augmentent localement cet effet de barrière. Au contraire, la basse vallée de cette rivière est ouverte sur les perturbations en provenance du Nord (NO à NE). Au sud, les monts des Béni Snassene - Bni Bou Yahia atténuent l'effet des vents chauds et secs du Sud-Est et du Sud sur le climat et sur les zones humides littorales. (Dakki, 2003).

Les précipitations

Les précipitations sont très variées entre la haute, la moyenne et la basse Moulouya. La pluviométrie subit des modifications singulières d'une année sur l'autre.

La moyenne annuelle des précipitations dans le bassin de la Basse Moulouya varie entre 250 mm et 530 mm, Les zones les plus arrosées sont les montagnes méditerranéennes de Beni Snassene, celles de la chaîne des Horsts et les sommets occidentaux de Berkane (Figure 2, ABHM 2008).

Les dépressions de la moyenne vallée de Moulouya sont les régions les moins arrosées et où les précipitations n'atteignent pas les 200 mm/an. Les hauts plateaux reçoivent entre 200 et 300 mm/an, ainsi que les contreforts des massifs de moyen et haut Atlas, le sillon de Taourirt-Oujda et la haute Moulouya (Melhaoui et Boudot 2009).




FIGURE 1.2 – Carte des précipitations moyennes dans le bassin hydraulique de la Moulouya

1.2 Changement climatique

Le climat est perçu comme changeant à l'échelle mondiale et on s'inquiète de plus en plus de la direction et des effets de ces changements. Ces préoccupations sont reflétées dans la Convention-cadre des Nations Unies sur les changements climatiques (CCNUCC) rédigée lors du Sommet de la Terre à Rio en juin 1992. La CCNUCC exige que les Parties non visées à l'annexe 1 (c'est-à-dire les pays en développement) mènent des évaluations de la vulnérabilité et de l'adaptation au changement climatique. Ces évaluations explorent et, si possible, quantifient la vulnérabilité de divers systèmes et secteurs à la variabilité et au changement climatiques à l'échelle nationale.

Le Groupe d'experts intergouvernemental sur l'évolution du climat (GIEC) a été créé en 1988 par l'Organisation météorologique mondiale (OMM) et le Programme des Nations Unies pour l'environnement (PNUE) pour fournir une évaluation de tous les aspects du changement climatique (CC), y compris la façon dont les activités humaines peuvent causer de tels changements. changements et peuvent être impactés par ceux-ci. Les changements futurs projetés par le GIEC (Cubasch et al. 2001) comprennent :

- L'augmentation globale de la température de l'air en surface est projetée dans tous les scénarios et par tous les modèles. Les modèles de circulation générale atmosphère-océan (AOGCM) prévoient une augmentation moyenne globale de la température de l'air en surface de +3 °C (allant de 1,3 °C à 4,5°C) pour un scénario d'« émissions élevées à l'échelle mondiale » (appelé scénario « A2 »), et de +2,2°C (allant de 0,9°C à 3,4°C) pour un scénario « moindres émissions de CO₂ » (appelé scénario « B2 ») pour la période 2071-2100 par rapport à 1961-1990. Des modèles climatiques plus simples, qui peuvent être calibrés pour représenter les réponses AOGCM moyennées à l'échelle mondiale, peuvent être exécutés pour un très grand nombre de scénarios car ils ne sont pas coûteux en termes de calcul : ceux-ci estiment une augmentation de 1,4 °C à 5,8 °C sur la période 1990-2100 pour gamme complète de scénarios d'émissions élaborés par le GIEC.
- Augmentation globale de la vapeur d'eau moyenne, de l'évaporation et des précipitations en conséquence de l'augmentation de la température qui accélère le cycle hydrologique. L'augmentation et la diminution des précipitations se produiront simultanément dans différentes régions.
- Augmentation de la fréquence des journées chaudes et des vagues de chaleur sur toutes les zones terrestres et, en particulier, dans les zones où se produit une diminution de l'humidité du sol. L'indice de chaleur (une mesure des effets combinés de la température et de l'humidité) devrait augmenter en raison des changements de la température de l'air en surface et de l'humidité absolue de l'air près de la surface.
- Augmentation globale de l'intensité et de la fréquence des événements de précipitations extrêmes.

Chapitre 2

Traitement des données

2.1 Construction de la base de données

Dans cette partie, nous montrons les étapes de préparation de la base des données. FSEC nous a proposé deux bases de données gérées par la Direction générale de la météologie "DGM" et l'autre par les postes pluviométriques gérées par l'agence du bassin de la Moulouya "ABHM" .

La première base de données générée par DGM : les précipitations journalières dans les deux stations MIDELE et OUJDA entre 1978 et 2018.(dans un seul fichier Excel)

La deuxième base des données générée par ABHM : les précipitations mensuelles dans 57 stations entre 1924 et 2018.(chaque station dans un fichier Excel).

 Pm A.B.MATHAR	28/02/2022 09:26	Feuille de calcul Microsoft Excel 97-2003	277 Ko
 Pm ALMIS DES MARMOUCHA	28/02/2022 09:28	Feuille de calcul Microsoft Excel 97-2003	200 Ko
 Pm ANNEXE GUERCIF	28/02/2022 09:56	Feuille de calcul Microsoft Excel 97-2003	250 Ko
 Pm ANSEGIMIR	28/02/2022 10:03	Feuille de calcul Microsoft Excel 97-2003	295 Ko
 Pm ANZAR OU FOUNES	28/02/2022 11:41	Feuille de calcul Microsoft Excel 97-2003	235 Ko
 Pm AVAL PONT DE SAKKA	28/02/2022 11:47	Feuille de calcul Microsoft Excel 97-2003	277 Ko
 Pm BARRAGE ENJIL	28/02/2022 11:54	Feuille de calcul Microsoft Excel 97-2003	282 Ko
 Pm BARRAGE HASSAN II MIDELE	28/02/2022 12:00	Feuille de calcul Microsoft Excel 97-2003	219 Ko
 Pm Belfarah	28/02/2022 12:05	Feuille de calcul Microsoft Excel 97-2003	280 Ko
 Pm BERKANE	28/02/2022 12:12	Feuille de calcul Microsoft Excel 97-2003	300 Ko
 Pm Berkine	28/02/2022 17:50	Feuille de calcul Microsoft Excel 97-2003	360 Ko
 Pm Bessara	22/02/2022 11:40	Feuille de calcul Microsoft Excel 97-2003	180 Ko
 Pm BGE M.HOMADI	28/02/2022 12:40	Feuille de calcul Microsoft Excel 97-2003	327 Ko
 Pm BGE Med V	28/02/2022 14:18	Feuille de calcul Microsoft Excel 97-2003	260 Ko
 Pm BGE SUR OUED ZA	28/02/2022 14:34	Feuille de calcul Microsoft Excel 97-2003	272 Ko
 Pm Bni Boufrah	28/02/2022 14:34	Feuille de calcul Microsoft Excel 97-2003	216 Ko
 Pm BOUARFA D.P.E	28/02/2022 15:54	Feuille de calcul Microsoft Excel 97-2003	192 Ko
 Pm BOUARFA SMN	28/02/2022 14:36	Feuille de calcul Microsoft Excel 97-2003	238 Ko
 Pm BOUGHRIHA SMVA	28/02/2022 16:49	Feuille de calcul Microsoft Excel 97-2003	379 Ko
 Pm BOURID	28/02/2022 14:38	Feuille de calcul Microsoft Excel 97-2003	284 Ko
 Pm DAR DRIOUCH	28/02/2022 14:38	Feuille de calcul Microsoft Excel 97-2003	201 Ko
 Pm DELEGATION MIDELE	28/02/2022 14:39	Feuille de calcul Microsoft Excel 97-2003	264 Ko
 Pm DOURA	28/02/2022 14:40	Feuille de calcul Microsoft Excel 97-2003	204 Ko
 Pm DPE Taza	28/02/2022 14:57	Feuille de calcul Microsoft Excel 97-2003	231 Ko
 Pm ECHOUYEB	28/02/2022 14:41	Feuille de calcul Microsoft Excel 97-2003	203 Ko
 Pm EL AOUIA	28/02/2022 14:42	Feuille de calcul Microsoft Excel 97-2003	262 Ko
 Pm GENFOUDA	28/02/2022 17:37	Feuille de calcul Microsoft Excel 97-2003	286 Ko

FIGURE 2.2 – Base de données de ABHM

2.1.1 Les étapes :

1. transformation des Pm format Grille en format date valeur.
2. Pour les postes gérés par DGM, il faut calculer des Pm (la somme des PJ du mois) pour chaque poste.

14967	MIDELT	22/12/2018	0
14968	MIDELT	23/12/2018	0
14969	MIDELT	24/12/2018	0
14970	MIDELT	25/12/2018	0
14971	MIDELT	26/12/2018	0
14972	MIDELT	27/12/2018	0
14973	MIDELT	28/12/2018	0
14974	MIDELT	29/12/2018	0
14975	MIDELT	30/12/2018	0
14976	MIDELT	31/12/2018	0
14977	OUJDA	01/01/1978	0
14978	OUJDA	02/01/1978	0
14979	OUJDA	03/01/1978	0
14980	OUJDA	04/01/1978	0,2
14981	OUJDA	05/01/1978	0
14982	OUJDA	06/01/1978	0
14983	OUJDA	07/01/1978	0
14984	OUJDA	08/01/1978	0
14985	OUJDA	09/01/1978	0
14986	OUJDA	10/01/1978	0
14987	OUJDA	11/01/1978	3

FIGURE 2.1 – Base de données de la DGM

3. Mise en forme : Consolidation des fichiers et constitution d'une base de données. (Voir le code Annexe A)
4. Calcul du pourcentage des lacunes pour chaque poste.
5. Comblement des lacunes par différentes méthodes à savoir K-NN, MICE et Missforest.

2.1.2 Choix sur la période d'étude :

Donc pour choisir la période d'étude, nous allons calculer les pourcentages des valeurs manquantes par date.

Date	
2000-07-01	0.152542
2000-04-01	0.152542
2000-08-01	0.152542
1998-08-01	0.152542
2000-03-01	0.152542
...	...
1941-11-01	0.983051
1941-10-01	0.983051
1941-09-01	0.983051
1942-10-01	0.983051
1924-01-01	0.983051

1121 rows × 1 columns

FIGURE 2.3 – Extrait du pourcentage des valeurs manquantes par date

Nous remarquons qu'il y a plus de valeurs manquantes dans les anciennes années que les années récentes. Donc la période d'étude choisie : 1978-2018.

2.1.3 Choix sur les stations d'étude :

Pour choisir les stations d'étude, nous allons calculer et ordonner les pourcentages des valeurs manquantes par station (pour toutes les 59 stations) :

A.B.MATHAR	0.000000
ZAIDA	0.000000
TLAT AZLEF	0.000000
TENDIT	0.000000
TAOURIRT	0.000000
OUTAT EL HADJ	0.000000
OUJDA_dgm	0.000000
MISSOUR	0.000000
MIDELT_dgm	0.000000
MELLOULOU GUERCIF	0.000000
MELG EL OUIDANE	0.000000
LAARICHAT	0.000000
DELEGATION MIDELT	0.000000
DAR DRIOUCH	0.000000
LOUGGAGH	0.000000
ANSEGMIR	0.000000
TABOUAZANT	0.002083
GENFOUDA	0.002083
EL AOUIA	0.002083
BERKANE	0.004167
AVAL PONT DE SAKKA	0.004167
SAFSAF	0.004167

BGE SUR OUED ZA	0.012500
SLIMANIA SMVA	0.018750
KSIBAT	0.066667
GUERCIF	0.079167
Belfarah	0.083333
OULED LAFKIR	0.158333
BERKINE	0.170833
OUJDA HAMRI	0.218750
BGE M.HOMADI	0.227083
OUJDA SMN	0.275000
MIDELT SMN	0.300000
NADOR SMN	0.300000
ANZAR OU FOUNES	0.368750
BOUARFA SMN	0.377083
GUEFAIT	0.406250
BOUGHRIBA SMVA	0.433333
DPE TAZA	0.454167
BOUARFA D.P.E	0.466667
BARRAGE ENJIL	0.481250
TAFORALT EF	0.593750
BARRAGE HASSAN II MIDELT	0.612500
TADDERT	0.614583
NAIMA EF	0.622917
TENDRARA	0.643750
bessara	0.727083
SKOURA	0.733333
TAOURIRT SMN	0.781250
Zebra Zaio	0.825000
Bni Boufrah	0.839583
BOURID	0.839583
ECHOUYEB	0.843750
TIZIOUSLI	0.843750
DOVIRA	0.875000
ALMIS DES MARMOUCHA	0.879167
BGE Med V	0.947917
TENDIT TAFRATA	0.952083
Souk Joumoua Tighrate	1.000000

le tableau suivant montre le pourcentage des valeurs manquantes dans toute la base des données en fonction du nombre des stations.

Nombre des stations à garder	Seuil : Pourcentage des NAN
16	0
27	0.1
29	0.2
34	0.3
36	0.4
41	0.5
42	0.6
46	0.7
49	0.8
56	0.9
59	1

TABLE 2.1 – Nombre de stations à garder en fonction du pourcentage accepté des NA



la figure ci-dessus montre le pourcentage des valeurs manquantes par ordre dans toutes les stations, donc on décide d'éliminer les stations qui contiennent énormément des valeurs manquantes.

Après observation, nous remarquons que la base des données est partagée en deux la première moitié où il y a plus des taches noires qui représentent les valeurs manquantes dans les stations correspondantes. La deuxième moitié où il y a moins des taches noires, ce qui désigne, moins des NAN.

le tableau suivant représente une description statistique des pourcentages des NAN :

pourcentage_des_nan	
count	59.000000
mean	0.323588
std	0.346877
min	0.000000
25%	0.000000
50%	0.218750
75%	0.618750
max	1.000000

FIGURE 2.5 – Description statistique du pourcentage des NA pour les différentes stations




FIGURE 2.6 – Box-plot du pourcentage des NA pour les différentes stations

En se basant sur le raisonnement précédent, on adopte **la médiane** des pourcentages des NAN par station comme seuil maximal. En effet, on ne garde dans la suite de l'étude que les stations ayant un pourcentage des valeurs manquantes inférieur à 21,87.

```

0      A.B.MATHAR
1      ANSEGMIR
2      AVAL PONT DE SAKKA
3      BERKANE
4      BERKINE
5      BGE SUR OUED ZA
6      Belfarah
7      DAR DRIOUCH
8      DELEGATION MIDELT
9      EL AOUIA
10     GENFOUDA
11     GUERCIF
12     KSIBAT
13     LAARICHAT
14     LOUGGAGH
15     MELG EL OUIDANE
16     MELLOULOU GUERCIF
17     MIDELT_dgm
18     MISSOUR
19     OUJDA HAMRI
20     OUJDA_dgm
21     OULED LAFKIR
22     OUTAT EL HADJ
23     SAFSAF
24     SLIMANIA SMVA
25     TABOUAZANT
26     TAOURIRT
27     TENDIT
28     TLAT AZLEF
29     ZAIDA

```

2.1.4 La base de données finale non imputée :

	A.B.MATHAR	ANSEGMIR	AVAL PONT DE SAKKA	BERKANE	BERKINE	BGE SUR OUED ZA	Belfarah	DAR DRIOUCH	DELEGATION MIDELT	EL AOUIA	...	OUJDA_dgm	OULED LAFKIR	OUTAT EL HADJ	SAFSAF	...
0	11.2	19.7	9.6	35.6	10.1	16.2	18.5	14.1	16.7	6.3	...	19.8	16.1	3.2	12.0	...
1	18.6	28.3	16.5	17.1	19.6	9.3	0.0	35.6	13.5	30.6	...	12.3	3.5	8.9	11.6	...
2	3.9	2.4	0.0	24.1	0.0	11.7	19.7	9.8	2.2	2.0	...	25.6	0.0	0.0	3.4	...
3	26.4	31.1	23.8	87.9	20.0	30.1	22.0	28.6	28.3	18.5	...	73.2	41.6	5.7	59.2	...
4	10.8	18.9	3.2	17.0	0.0	5.4	9.6	8.8	40.4	15.0	...	21.6	6.8	17.0	1.9	...
...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...	...
475	14.2	10.7	3.4	12.5	58.5	11.8	NaN	24.9	8.5	79.5	...	5.6	NaN	20.6	16.5	...
476	13.4	0.6	6.4	2.0	8.3	10.2	NaN	2.1	2.3	20.5	...	4.2	NaN	0.4	0.0	...
477	7.6	16.5	0.0	NaN	4.2	6.6	NaN	5.5	7.1	8.5	...	10.9	NaN	0.0	NaN	...
478	0.4	3.4	14.1	33.1	5.7	13.0	NaN	12.7	1.2	7.5	...	20.4	NaN	0.3	18.1	...
479	6.0	0.9	5.5	30.2	4.2	14.6	NaN	15.6	1.9	11.5	...	38.0	NaN	3.8	17.2	...

480 rows x 30 columns

FIGURE 2.7 – Extrait de la base de données finale avant imputation

Nous avons pu obtenir une base de données qui contient les précipitations mensuelles de chaque centre entre 1978 et 2017. Donc dans la phase suivante, nous allons alors combler les lacunes (valeurs manquantes) par : la méthode des K-nearest neighbors – KNN (la méthode des K-plus proches voisins) (Troyanskaya et al., 2001), multivariate imputation

by chained equations – MICE (imputation multivariée par équations en chaîne) (Buuren et Oudshoorn, 1999) et missForest (Stekhoven et Bühlmann, 2012).

2.2 Imputation de données manquantes

2.2.1 Généralités sur l'imputation

Les données climatiques ont une importance capitale pour l'étude du changement climatique, notamment les canicules et les vagues de chaleur. Parfois les séries de ces données présentent des lacunes sur des périodes temporaires aléatoirement réparties dans le temps, ceci est dû à plusieurs facteurs : panne de l'instrument de mesure, indisponibilité de site, problème de transmission de la donnée, problème d'archivage... Pour reconstituer ces données manquantes, les chercheurs font recours à des méthodes pour combler les « trous » dans des bases de données incomplètes par des valeurs substituées et identifiées comme des « données imputées », ce qu'on appelle l'imputation.

2.2.1.1 Catégories de méthodes d'imputation

☐ Le nombre d'imputations

- **Méthodes à imputation unique** : la plupart des méthodes d'imputation existantes entrent dans cette catégorie. Le principe de l'imputation unique vise à imputer une donnée manquante une seule fois ; une seule valeur lui est donc associée.
- **Méthodes à imputation multiple** : ces algorithmes génèrent plusieurs versions différentes de la base de données imputée. Une fois les imputations multiples terminées, une analyse est menée sur chaque base de données imputée et suite à cette analyse, les résultats sont combinés pour obtenir une base de données complète.

☐ La nature paramétrique ou non

Les méthodes paramétriques imputent les données manquantes en faisant des suppositions sur la distribution des variables à partir des données observables. Cette distribution dépend du réglage d'un ensemble de paramètres fixes. Ce type de fonctionnement peut induire un biais, car les suppositions faites sur la distribution des données ne sont pas nécessairement vérifiées. Par exemple, certaines de ces méthodes définissent les variables quantitatives par l'intermédiaire de termes linéaires et sans interactions, des termes non linéaires déterminants peuvent donc être omis. C'est notamment le cas de la régression linéaire. À l'inverse, les méthodes non paramétriques ne sont pas régies par des lois de probabilités paramétriques et ne font donc pas de supposition sur la distribution des données.

2.2.1.2 Conditions d'application

Parce que l'algorithme des méthodes d'imputation diffèrent dans leur manière d'imputer des données, leurs conditions d'application également. En effet, selon l'approche d'imputation utilisée, les caractéristiques de la base de données à imputer peuvent rendre impossible

l'imputation des données. Deux critères identifiés à partir de la littérature sont susceptibles d'avoir un impact sur la capacité des méthodes à imputer : la structure de la base de données et le type de manque de données rencontré.

□ Caractéristiques structurelles des bases de données

Selon leur approche d'imputation (approches à imputation unique ou multiple et de type paramétrique ou non paramétrique), les méthodes ne sont pas impactées de la même manière par les caractéristiques structurelles d'une base de données. En raison des hypothèses faites sur la distribution des données, ce sont les méthodes paramétriques qui sont les plus affectées. Par exemple, à cause de l'hypothèse de linéarité faite par certaines de ces méthodes (comme la régression linéaire), une non-linéarité dans le système peut induire un biais dans les résultats. Par ailleurs, ces méthodes peuvent rencontrer des difficultés à traiter les bases de données dans lesquelles deux variables sont hautement corrélées.

□ Type de manque de données

Une classification récente, majoritairement employée actuellement, différencie trois types de manque de données :

- **Manque aléatoire – MA** (missing completely at random) : les données manquantes constituent un sous-ensemble aléatoire de l'ensemble des données. La distribution des données manquantes est supposément identique à celle des données observées. C'est néanmoins une hypothèse stricte.
- **Manque dépendant des observations – MDO** (missing at random) : dans le cas MDO, le manque de données n'est pas aléatoire. La probabilité qu'un élément soit manquant dépend des autres variables observables du système.
- **Manque non aléatoire – MNA** (not missing at random) : les données MNA sont les données qui ne sont ni MA, ni MDO. Ici la probabilité qu'un élément soit manquant dépend directement de sa propre valeur.

Dans la pratique, de ces trois types de manque différents, seules les données MA sont empiriquement vérifiables par des tests statistiques. À l'inverse, les données MDO et MNA ne peuvent être vérifiées ou différenciées car elles dépendent de données non observables.

De nombreuses méthodes ne fournissent d'estimateurs que dans le cas de données MA et un biais peut résulter d'un non-respect de cette supposition de départ. C'est pourquoi la plupart des études de ce domaine ont été effectuées sur des données MA.

2.2.2 Les principales méthodes d'imputations

2.2.2.1 KNN

KNN est une méthode d'imputation basée sur la recherche des K plus proches voisins. Elle a été initialement introduite pour l'étude de l'expression des gènes. Soit une base de données avec n enregistrements et p variables et en son sein, une donnée manquante à l'enregistrement i . L'imputation de cette donnée s'effectue en deux étapes :

Méthode	Paramétrique	Itérative	Imputation unique	Apprentissage automatique
KNN	Non	Non	Oui	Oui
MICE	Oui	Oui	Non	Non
MissForest	Non	Oui	Oui	Oui

TABLE 2.2 – Caractéristiques des méthodes d’imputation de données manquantes utilisées

- **Étape 1** : les distances entre les $n-1$ paires d’enregistrements (qui contiennent l’enregistrement i) sont calculées à partir des variables complètes afin d’identifier les K plus proches voisins de l’enregistrement i .
- **Étape 2** : la donnée manquante de l’enregistrement i est calculée à partir des K plus proches voisins qui possèdent la donnée associée à la variable concernée. Pour les données quantitatives, il s’agit de faire une moyenne des données des K plus proches voisins. Pour les données qualitatives, c’est un vote sur la majorité sur les K données.

Même si cela peut paraître contre-intuitif, la méthode KNN n’est pas paramétrique. C’est en raison du fait que le nombre de paramètres n’augmente pas avec le nombre de dimensions du système. De plus, K est un hyper paramètre ; il ne peut donc pas être déterminé par l’algorithme KNN et est à fixer par l’utilisateur.

2.2.2.2 MICE

MICE (Buuren et Oudshoorn, 1999) est une méthode paramétrique qui attribue un modèle d’imputation différent pour chaque variable dont les prédicteurs sont les autres variables du système. C’est une méthode itérative, c’est-à-dire que MICE impute les données manquantes une nouvelle fois à chaque itération en se basant sur les résultats obtenus à l’itération précédente jusqu’à ce que le critère d’arrêt soit atteint. L’imputation avec MICE s’effectue en cinq étapes :

- **Étape 1** : une première imputation temporaire est effectuée pour imputer les variables incomplètes du système. En général, c’est une imputation par la moyenne.
- **Étape 2** : les données précédemment imputées sont réinitialisées à « manquantes » pour une seule des variables du système.
- **Étape 3** : les données manquantes de cette variable sont ensuite imputées à nouveau grâce aux autres variables (complètes) du système qui servent de prédicteurs à son modèle d’imputation spécifique. Ces données nouvellement imputées seront utilisées lorsque cette variable servira de prédicteur aux autres variables du système.
- **Étape 4** : les étapes 2 et 3 sont répétées pour toutes les variables du système jusqu’à ce que chaque donnée manquante soit imputée. À cet instant, une itération est terminée.
- **Étape 5** : les étapes 2 jusqu’à 4 sont répétées le nombre de fois précisé par l’utilisateur et les données imputées sont mises à jour à chaque itération. Les prédicteurs sont donc de plus en plus précis et les paramètres responsables de l’imputation sont de plus en plus stables.

MICE étant une méthode à imputations multiple, la procédure d’imputation est répétée m fois pour créer m bases de données imputées qui seront mises en commun après avoir été analysées.

2.2.2.3 MissForest

Cette troisième méthode d'imputation est la plus récente des trois abordées (Stekhoven et Bühlmann, 2012). C'est une méthode basée sur le principe des forêts aléatoires (Breiman, 2001). Le choix de Stekhoven et Bühlmann s'est porté sur les forêts aléatoires de Breiman en raison de leur polyvalence : elles peuvent traiter les problèmes à haute dimension, contenant des données de type mixte et avec des structures complexes. Ces forêts sont une combinaison de deux idées : les arbres de décisions et le bootstrap aggregating – bagging (l'agrégation de modèles).

En utilisant les travaux de Breiman, Stekhoven et Bühlmann introduisent missForest en 2012. Son fonctionnement itératif n'est pas sans rappeler celui de MICE et peut le diviser en six étapes :

- **Étape 1** : une première imputation temporaire est effectuée pour imputer les variables incomplètes du système. En général c'est une imputation par la moyenne.
- **Étape 2** : les variables sont classées par ordre croissant du pourcentage de données manquantes.
- **Étape 3** : les données précédemment imputées sont réinitialisées à « manquantes » pour une seule des variables du système.
- **Étape 4** : les données manquantes de cette variable sont ensuite imputées à nouveau grâce à une forêt aléatoire bâtie à partir des autres variables du système.
- **Étape 5** : les étapes 3 et 4 sont répétées pour toutes les variables du système jusqu'à ce que chaque donnée manquante soit imputée. À cet instant, une itération est terminée.
- **Étape 6** : les étapes 3 jusqu'à 5 sont répétées jusqu'à ce que la différence entre la matrice dernièrement imputée et la matrice imputée à l'itération précédente cesse de diminuer.

2.2.3 Analyse de la performance et validation de la méthode choisie

2.2.3.1 Méthodologie de mesure de performance

Pour mesurer la performance des trois méthodes (Knn, Mice, MissForest), on utilise une base de données de test, c'est-à-dire une base de données complète dont un pourcentage de ces éléments sera ensuite remplacés par des valeurs manquantes. Après, on essaye de trouver laquelle des méthodes d'imputations donnent le meilleur résultat, c'est-à-dire laquelle approche le mieux la base de données originale. Pour cela, on définit un indice de performance qui permettra de comparer les méthodes utilisées.

- **Base de données utilisée** : Comme le montre la figure 2.4, 16 stations n'ont aucune valeur manquante. Du coup, nous pouvons utiliser la base de données est constituée des précipitations de ces 16 villes durant les 40 ans choisis, ce qui constitue une base de donnée complète. On remplace aléatoirement un pourcentage des valeurs de cette base par des valeurs manquantes.
- **Indice de performance utilisé** : Pour évaluer la performance des méthodes d'imputation, nous calculons d'abord l'erreur quadratique moyenne normalisée (NRMSE) pour chaque variable de l'ensemble de données. La formule de calcul du NRMSE

pour chaque variable de l'ensemble de données est donnée comme suit :

$$NRMSE = \sqrt{\frac{\text{mean}((\text{original value} - \text{imputed value})^2)}{\text{max}(\text{original value}) - \text{min}(\text{original value})}}$$

Où la valeur originale est la valeur réelle de la variable et la valeur imputée est la valeur de la variable après imputation. Après avoir calculé le NRMSE pour chaque variable de l'ensemble de données, le NRMSE moyen est calculé comme suit :

$$\text{Mean NRMSE} = \frac{\sum_{i=1}^n NRMSE}{n}$$

Où n est le nombre de variables dans l'ensemble de données. Dans notre cas, ce nombre est 16.

Plus faible est la valeur de la NRMSE moyenne ; meilleure est l'estimation des valeurs manquantes.

2.2.3.2 Application et Résultats

Le NRMSE moyen pour l'ensemble de données pour différents pourcentages de données imputées à l'aide de différentes méthodes d'imputation est calculé et indiqué dans les tableaux. Chaque colonne du tableau indique le pourcentage de données imputées et chaque ligne indique la méthode utilisée pour l'imputation des données. La valeur en gras indique la NRMSE moyenne la plus faible. Cela signifie que la valeur en gras indique la méthode d'imputation qui donne le meilleur résultat d'imputation lorsqu'elle est appliquée à l'ensemble de données donné. Le graphique de la méthode d'imputation et la NRMSE moyenne correspondante pour différents pourcentages des valeurs manquantes pour tous les ensembles de données utilisés dans l'étude sont illustrés à la figure.

```
> a
      NRMSE mean in %
missForest_method    15.58750
mice_method          22.28125
knn_method           20.10000
> b
      NRMSE mean in %
missForest_method    26.31875
mice_method          31.21875
knn_method           38.70625
> c
      NRMSE mean in %
missForest_method    32.13750
mice_method          43.12500
knn_method           47.45625
> d
      NRMSE mean in %
missForest_method    38.18750
mice_method          49.68125
knn_method           58.83125
> e
```

NRMSE mean in %

```
missForest_method      44.25625
mice_method             62.50625
knn_method              67.76250
```

Method Used for Data Imputation	% of miss				
	10%	20%	30%	40%	50%
MissForest	15.59	26.32	32.14	38.19	44.26
Mice	22.28	31.22	43.12	49.68	62.51
Knn	20.10	38.71	47.46	58.83	67.76

TABLE 2.3 – Moyenne NRMSE pour les différents pourcentages des valeurs manquantes




FIGURE 2.8 – Plot of imputation method versus mean NRMSE

On observe qu'à mesure que le pourcentage de valeurs manquantes augmente, la NRMSE moyenne augmente également. On observe également que la moyenne de la NRMSE est la plus faible pour la méthode MissForest pour tous les pourcentages des valeurs manquantes. Donc, la méthode MissForest semble la plus puissante. Par la suite, la méthode d'imputation qu'on utilise pour notre base de donnée est bien MissForest. Et la base de donnée ainsi obtenue sera utilisé dans les parties qui suivent.

En général la méthode Missforest est la plus performante, la méthode MICE, et K-MN en dernière position.

2.2.4 Base de données finale imputée avec la méthode MissForest.

Cette base de données est complète "Les précipitations sensuelles entre 1978 et 2018 ", elle contient 480 observations de 30 stations. Dans la suite de l'étude, on se base sur cette dernière :

date	A.B.MATHAR	ANSGOMR	ANAL.PONT.DE.SAKKA	BERKANE	BERKINE	BGE.SUR.OUED.ZA	Bettarsh	DAR.DRIOUCH	DELEGATION.MIDELT	...	OUJ
0 1978-01-01	11.2	19.7	9.6	35.600	10.1	16.2	18.500	14.1	16.7	...	...
1 1978-02-01	18.6	28.3	16.5	17.100	19.6	9.3	0.000	35.6	13.5	...	...
2 1978-03-01	3.9	2.4	0.0	24.100	0.0	11.7	19.700	9.8	2.2	...	...
3 1978-04-01	26.4	31.1	23.8	87.900	20.0	30.1	22.000	28.6	28.3	...	...
4 1978-05-01	10.8	18.9	3.2	17.000	0.0	5.4	9.600	8.8	40.4	...	...
...	...	...	...	...	...	...	...	...	...	...	...
475 2017-06-01	14.2	10.7	3.4	12.500	58.5	11.8	17.587	24.9	8.5	...	...
476 2017-09-01	13.4	0.6	6.4	2.000	8.3	10.2	7.338	2.1	2.3	...	...
477 2017-10-01	7.6	16.5	0.0	13.743	4.2	6.6	15.943	5.5	7.1	...	...
478 2017-11-01	0.4	3.4	14.1	33.100	5.7	13.0	14.167	12.7	1.2	...	...
479 2017-12-01	6.0	0.9	5.5	30.200	4.2	14.6	17.411	15.6	1.9	...	...

FIGURE 2.9 – Extrait de la base de donnée finale après imputation

2.3 Visualisations.

On cherche d'abord à visualiser les séries pour remarquer leurs évolutions dans le temps :





FIGURE 2.10 – visualisation dynamique des précipitations dans toutes les stations en fonction du temps (voir Jupyter Notebook)

2.3.1 les boîtes à moustaches par mois

Nous allons visualiser les box-plot pour obtenir les points aberrants et pour représenter les mois extrêmes ayant plus ou moins de précipitation durant toute la période d'étude :



Les figures suivantes nous donnent seulement une idée sur les saisons les plus et les moins pluvieuses durant toute la période.


On remarque alors pour toutes les 30 stations qu'en moyenne, il y a deux formes de courbe centrées par une stabilité, la première est concave, la deuxième est convexe. ce qui montre qu'il y a plus de précipitation de janvier à mai, une faible précipitation de mai à septembre et une augmentation encore d'octobre à décembre.

NB) Notons que la moyenne est faite pour les précipitations de chaque mois durant toute la période de 1978 jusqu'à 2018.

Les box-plot représentent les mois ayant plus ou moins de précipitation durant toute la période d'étude.


(Voir le reste des figures dans le Notebook).

2.3.2 les boîtes à moustaches par an.





Ces Box-plot nous permettent de noter des années de précipitations extrêmes, à savoir 2004-2008-2010 tout dernièrement, ce qui explique les inondations subies au Maroc le 10 octobre 2008. (Voir le reste des figures dans le Notebook).



box-plot des séries par station

En terme des stations, Le Box-plot montre que les moyennes des précipitations durant toute la période d'étude pour chaque station sont proches. Mais, on constate des valeurs extrêmes pour chaque station. Par exemple les valeurs en jaune.

2.4 Statistique descriptive

2.4.1 Approche classique

A.B.MATHAR	ANSEGMIR	A.P.SAKKA	BERKANE	BERKINE	BGE.OUED.ZA
Min. : 0.00	Min. : 0.00	Min. : 0.00	Min. : 0.00	Min. : 0.000	Min. : 0.00
1st Qu.: 4.00	1st Qu.: 3.00	1st Qu.: 0.00	1st Qu.: 1.80	1st Qu.: 4.875	1st Qu.: 1.50
Median : 11.90	Median : 10.85	Median : 6.45	Median : 13.90	Median : 13.150	Median : 10.60
Mean : 16.59	Mean : 16.71	Mean : 11.45	Mean : 25.34	Mean : 19.188	Mean : 18.30
3rd Qu.: 22.93	3rd Qu.: 23.43	3rd Qu.: 17.00	3rd Qu.: 34.10	3rd Qu.: 26.025	3rd Qu.: 26.40
Max. : 117.00	Max. : 123.40	Max. : 121.00	Max. : 232.50	Max. : 156.900	Max. : 265.00
Belfarah	DAR.DRIOUCH	DELEG.MIDELT	EL.AOUIA	GENFOUDA	GUERCIF
Min. : 0.000	Min. : 0.00	Min. : 0.00	Min. : 0.00	Min. : 0.00	Min. : 0.00
1st Qu.: 1.475	1st Qu.: 1.90	1st Qu.: 2.60	1st Qu.: 6.30	1st Qu.: 3.40	1st Qu.: 1.10
Median : 9.600	Median : 11.05	Median : 9.40	Median : 16.95	Median : 13.75	Median : 6.90
Mean : 14.607	Mean : 20.24	Mean : 15.59	Mean : 26.17	Mean : 20.23	Mean : 13.30
3rd Qu.: 20.022	3rd Qu.: 27.93	3rd Qu.: 21.93	3rd Qu.: 36.15	3rd Qu.: 28.93	3rd Qu.: 18.90
Max. : 120.300	Max. : 268.40	Max. : 137.10	Max. : 178.70	Max. : 166.10	Max. : 220.30
KSIBAT	LAARICHAT	LOUGGAGH	MELG.El.OUIDANE	MELLOULOU	MIDELT_dgm
Min. : 0.00	Min. : 0.00	Min. : 0.000	Min. : 0.00	Min. : 0.000	Min. : 0.00
1st Qu.: 0.00	1st Qu.: 0.00	1st Qu.: 9.175	1st Qu.: 0.90	1st Qu.: 1.175	1st Qu.: 3.40
Median : 5.45	Median : 6.40	Median : 22.400	Median : 8.30	Median : 7.450	Median : 9.30
Mean : 10.60	Mean : 14.34	Mean : 32.013	Mean : 14.14	Mean : 12.909	Mean : 14.40
3rd Qu.: 14.53	3rd Qu.: 18.80	3rd Qu.: 43.850	3rd Qu.: 21.12	3rd Qu.: 18.125	3rd Qu.: 20.90
Max. : 99.00	Max. : 163.50	Max. : 266.600	Max. : 119.40	Max. : 203.000	Max. : 136.30
MISSOUR	OIJDA.HAMRI	OIJDA_dgm	OULED.LAFKIR	OUTAT.EL.HADJ	SAFSAF
Min. : 0.00	Min. : 0.00	Min. : 0.000	Min. : 0.000	Min. : 0.00	Min. : 0.00
1st Qu.: 1.50	1st Qu.: 3.90	1st Qu.: 3.375	1st Qu.: 0.000	1st Qu.: 0.70	1st Qu.: 0.80

Median : 6.40	Median : 17.75	Median : 14.500	Median : 5.814	Median : 5.15	Median : 11.00
Mean : 12.74	Mean : 24.05	Mean : 22.020	Mean : 12.257	Mean : 11.06	Mean : 19.60
3rd Qu.: 17.30	3rd Qu.: 34.50	3rd Qu.: 31.950	3rd Qu.: 16.925	3rd Qu.: 16.00	3rd Qu.: 27.00
Max. : 97.20	Max. : 197.00	Max. : 181.100	Max. : 127.700	Max. : 112.60	Max. : 202.40
SLIMANIA.SMVA	TABOUAZANT	TAOURIRT	TENDIT	TLAT.AZLEF	ZAIDA
Min. : 0.000	Min. : 0.00	Min. : 0.00	Min. : 0.000	Min. : 0.00	Min. : 0.00
1st Qu.: 2.175	1st Qu.: 8.10	1st Qu.: 1.15	1st Qu.: 0.675	1st Qu.: 2.00	1st Qu.: 3.30
Median : 14.750	Median : 20.25	Median : 8.55	Median : 4.900	Median : 10.30	Median : 12.40
Mean : 25.842	Mean : 28.62	Mean : 15.23	Mean : 9.967	Mean : 21.67	Mean : 17.00
3rd Qu.: 34.500	3rd Qu.: 41.70	3rd Qu.: 22.80	3rd Qu.: 13.325	3rd Qu.: 29.90	3rd Qu.: 25.30
Max. : 260.300	Max. : 216.40	Max. : 139.50	Max. : 110.000	Max. : 296.50	Max. : 93.10

Interprétation :

Nous remarquons que les précipitations varient en moyenne dans toutes les stations d'étude durant toute la période de 40 ans entre : 9,96 pour la station de **TENDIT** et 32 pour la station **LOUGGAGH**.

Le premier quartile Q1 : la plus petite valeur de la série telle qu'au moins 25% Donc Q 1 est entre 0 pour plusieurs stations et 6.30 pour **EL.AOUIA**.

Le troisième quartile Q3 : est la plus petite valeur de la série telle qu'au moins 75% Donc Q3 est entre 13.325 pour **TENDIT** et 43.850 pour **LOUGGAGH**.

cette statistique descriptive nous permet juste de comparer les stations durant toute la période d'étude, ce qui nous ne permet pas de détecter les périodes critiques, l'effet des saisons de l'année et les stations critiques, c.-à-d. les plus et les moins pluvieuses. En outre, l'évolution des précipitations est cachée. On passe à une approche plus détaillée : l'approche saisonnière.

2.4.2 Approche saisonnière

Maintenant, afin de bien montrer l'effet des saisons sur nos statistiques, nous allons refaire la description, mais cette fois chaque saison indépendamment de l'autre. Pour que la saison d'hiver ne compense pas la saison d'été par exemple. on ajoute une colonne de saison correspond à chaque mois de l'année, donc par défaut, on choisit les mois 12,1,2 dans la 1 saison : **l'hiver**. le mois 3,4,5 dans la 2 : **Printemps**, le mois 6,7,8 dans la 3 saison été, et 9,10,11 dans la dernière saison : **automne**.

Pour analyser chaque saison en particulier, on subdivise la base de données en 4 parties, chacune représente toutes les saisons de la période.

On cumule les précipitations de chaque année pour chaque saison, et on calcule leurs moyennes.

(voir les étapes avec les codes et les résultats dans l'annexe)




FIGURE 2.11 – Les précipitations moyennes en ordre pour la saison d’hiver

Interpretation : pour la saison 1 :L’hiver (mois 12-1-2) la station KSIBAT a eu en moyenne les plus faibles ppt 19,97 mm la station station berkane a eu en moyenne les ppt les plus élevees 112,78 mm.




FIGURE 2.12 – Les précipitations moyennes en ordre pour la saison de printemps

Interpretation : pour la saison 2 :Printemps(mois 3-4-5) la station TENDIT a eu en moyenne les plus faibles ppt 40,87 mm la station station LOUGGAGH a eu en moyenne les ppt les plus élevees 102,83 mm




FIGURE 2.13 – Les précipitations moyennes en ordre pour la saison d'été

Interpretation : pour la saison 3 :été (mois 6-7-8) la station SAFSAF a eu en moyenne les plus faibles ppt 6,58 mm la station station LOUGGAGH a eu en moyenne les ppt les plus élevees 71,37mm




FIGURE 2.14 – Les précipitations moyennes en ordre pour la saison d'automne

Interpretation : pour la saison 4 :Automne (mois 9-10-11). la station TENDIT a eu en moyenne les plus faibles ppt 43,63 mm la station station LOUGGAGH a eu en moyenne les ppt les plus élevees 136,79 mm

Stations	Hiver			Printemps			Été			Automne		
	mean	std	CV	mean	std	CV	mean	std	CV	mean	std	CV
A.B.MATHAR	46.66	23.17	49.66	55.69	29.68	53.30	26.54	19.04	71.72	70.20	47.82	68.12
ANSEGMIR	51.68	33.22	64.29	57.24	36.62	63.99	29.78	17.90	60.12	61.84	39.24	63.46
AVAL.PONT.DE.SAKKA	35.59	20.26	56.94	45.83	33.29	72.64	11.56	13.33	115.30	44.38	35.65	80.32
BERKANE	112.79	62.46	55.38	90.52	56.32	62.22	8.66	13.68	158.05	92.06	64.11	69.64
BERKINE	54.96	31.74	57.75	66.27	45.10	68.06	34.62	27.61	79.75	74.41	52.21	70.17
BGE.SUR.OUED.ZA	64.17	35.24	54.92	72.14	55.40	76.81	15.86	26.98	170.09	68.14	53.86	79.04
Belfarah	54.51	32.13	58.94	54.12	33.09	61.14	13.30	14.61	109.90	53.36	33.96	63.65
DAR.DRIOUCH	79.30	39.89	50.31	77.18	53.33	69.09	13.93	20.09	144.29	72.49	64.21	88.59
DELEGATION..MIDELT	38.53	25.35	65.79	58.10	35.71	61.46	27.99	19.12	68.32	62.47	38.31	61.33
EL.AOUIA	55.88	40.73	72.89	93.52	55.42	59.26	65.78	38.26	58.17	98.83	56.71	57.38
GENFOUDA	74.84	41.99	56.11	80.82	50.54	62.54	15.12	17.80	117.73	71.94	46.66	64.87
GUERCIF	43.70	24.09	55.13	54.29	45.82	84.39	12.05	16.96	140.73	49.93	37.14	74.38
KSIBAT	19.97	15.14	75.82	46.64	30.04	64.42	15.36	13.50	87.88	45.19	32.35	71.57
LAARICHAT	30.88	28.75	93.09	63.68	37.43	58.78	22.36	27.12	121.31	55.10	49.00	88.93
LOUGGAGH	73.15	42.32	57.85	102.83	61.44	59.75	71.38	44.75	62.70	136.80	81.78	59.78
MELG..ELOUIDANE	44.21	21.53	48.71	58.10	35.94	61.86	11.30	14.98	132.52	56.05	39.69	70.81
MELLOULOU.GUERCIF	42.64	23.83	55.88	51.64	42.16	81.63	11.63	13.08	112.53	48.99	36.04	73.58
MIDELT_dgm	34.37	19.14	55.68	52.74	33.89	64.27	29.22	20.77	71.10	56.73	35.95	63.36
MISSOUR	23.97	20.44	85.28	52.39	33.17	63.31	25.53	22.04	86.33	51.02	35.69	69.95
OUJDA.HAMRI	92.98	50.57	54.38	93.98	43.89	46.70	14.22	15.99	112.43	87.39	53.23	60.91
OUJDA_dgm	88.29	45.75	51.82	85.83	41.57	48.43	13.47	15.55	115.48	76.66	46.98	61.28
OULED.LAFKIR	42.03	24.65	58.65	50.70	43.38	85.57	8.05	13.38	166.35	46.31	35.97	77.67
OUTAT.EL.HADJ	21.26	16.18	76.10	48.49	29.06	59.92	16.29	13.38	82.13	46.69	36.17	77.49
SAFSAF	82.54	45.92	55.64	70.78	42.62	60.21	6.58	9.78	148.66	76.41	56.13	73.47
SLIMANIA.SMVA	110.89	55.44	50.00	93.68	59.87	63.91	8.81	12.38	140.48	96.73	60.84	62.89
TABOUAZANT	88.98	54.33	61.06	100.17	54.25	54.15	50.57	39.80	78.71	103.78	51.96	50.07
TAOURIRT	54.63	32.24	59.01	59.17	40.58	68.57	11.18	17.72	158.48	57.80	43.18	74.71
TENDIT	21.61	16.37	75.77	40.87	29.34	71.79	13.50	13.59	100.70	43.63	32.85	75.29
TLAT.AZLEF	76.51	48.85	63.85	81.24	61.44	75.63	19.16	25.06	130.80	83.18	74.02	88.99
ZAIDA	53.68	32.99	61.46	58.48	35.26	60.30	33.57	20.38	60.71	58.97	32.24	54.67

TABLE 2.4 – Analyse statistique des précipitations par saison et par station

Interprétation de tableau récapitulatif :

La variance de chaque saison par station donne une idée sur la dispersion des précipitations dans cette saison et cette station.

Autrement, plus la variance est importante, plus les valeurs sont écartées, d'où il y a des changements climatiques durant cette saison.

2.5 Segmentation de la zone d'étude

2.5.1 Introduction

Dans de nombreux cas, l'analyse de cluster traditionnelle, c'est-à-dire le clustering hiérarchique, est utilisée pour regrouper les séries chronologiques. Dans ce cas, une mesure de distance appropriée héritant des caractéristiques dynamiques de la série temporelle est d'abord définie pour comparer les séries temporelles et, successivement, une analyse de cluster hiérarchique standard est appliquée en utilisant la distance définie.

Le but de l'analyse typologique est d'affecter des unités (objets) à des clusters de sorte que les unités au sein de chaque cluster soient similaires les unes aux autres en ce qui concerne les variables observées, et que les clusters eux-mêmes se distinguent les uns des autres. En

d'autres termes, le but est de diviser les unités en grappes homogènes et distinctes (bien séparées). Généralement, les méthodes de clustering sont classées en méthodes de clustering hiérarchique et de clustering non hiérarchique (ou clustering partitionnel), basées sur les propriétés des clusters générés (Everitt et al., 2011 ; Xu et Wunsch, 2009). Le clustering hiérarchique regroupe les données avec une séquence de partitions imbriquées, soit de clusters singleton à un cluster incluant tous les individus, soit vice versa. Le premier est connu sous le nom de clustering agglomératif et le second est appelé clustering diviseur. Les méthodes de regroupement par agrégation et par division organisent les données dans la structure hiérarchique en fonction de mesures de proximité appropriées (c'est-à-dire des mesures de distance, des mesures de dissemblance, des indices de similarité).

2.5.2 Mesures de distance

Soit $\mathbf{X} = \{x_{ij} : 1, \dots, I; j = 1, \dots, J\} = \{\mathbf{x}_i = (x_{i1}, \dots, x_{ij}, \dots, x_{iJ})' : i = 1, \dots, I\}$ la matrice des données où x_{ij} représente la j-ième variable observée sur le i-ème objet et $\mathbf{x}_i$ représente le vecteur de la i-ème observation. La classe de mesure de distance la plus couramment utilisée dans l'analyse par grappes est la classe de distance de Minkowski (Everitt et al., 2011) :

$${}_r d_{il} = \left[\sum_{j=1}^J |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}}, r \geq 1$$

Pour $r=1$, nous avons la distance de Manhattan :

$${}_1 d_{il} = \sum_{j=1}^J |x_{ij} - x_{lj}|$$

Et pour $r=2$, nous avons la distance euclidienne, probablement la mesure de distance la plus couramment utilisée dans l'analyse de cluster :

$${}_2 d_{il} = \left[\sum_{j=1}^J |x_{ij} - x_{lj}|^2 \right]^{\frac{1}{2}}$$

Une version pondérée intéressante de la classe de distance précédente de Minkowski est (Everitt et al., 2011) :

$${}_r \tilde{d}_{il} = \left[\sum_{j=1}^J \omega_j^r |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}}, r \geq 1$$

Donc :

$${}_1 \tilde{d}_{il} = \sum_{j=1}^J \omega_j^1 |x_{ij} - x_{lj}| \quad (r = 1) \quad (\text{Distance de Manhattan pondérée})$$

$${}_2 \tilde{d}_{il} = \left[\sum_{j=1}^J \omega_j^2 |x_{ij} - x_{lj}|^2 \right]^{\frac{1}{2}} \quad (r = 2) \quad (\text{Distance euclidienne pondérée})$$

Où ω_j ($j = 1, \dots, J$) représente un poids approprié pour la j-ième variable.

Pour utiliser les mesures de distance dans les techniques de regroupement (c'est-à-dire dans le regroupement hiérarchique), il est utile de collecter toutes les distances pour chaque paire d'unités sous forme de matrice (au carré) ; par exemple, la matrice de distance de Minkowski peut être représentée comme suit :

$${}_r\mathbf{D} = \left\{ {}_r d_{il} = \left[\sum_{j=1}^J |x_{ij} - x_{lj}|^r \right]^{\frac{1}{r}} : i, l = 1, \dots, I \right\}, r \geq 1$$

2.5.3 Segmentation hiérarchique

Dans cette section, nous nous concentrons uniquement sur les méthodes agglomératives qui sont probablement les plus largement utilisées des méthodes hiérarchiques. Ils produisent une série de partitions des données : la première consiste en I clusters à membre unique ; le dernier consiste en un cluster unique contenant toutes les unités I (Everitt et al., 2011). Le clustering agglomératif commence par des clusters I , dont chacun comprend exactement un point de données. Une série d'opérations de fusion est ensuite suivie qui force finalement tous les objets dans le même groupe. Le regroupement agglomératif général peut être résumé par la procédure suivante (Xu et Wunsch, 2009) :

1. Commencez par les clusters I singleton. Calculez la matrice de proximité, par ex. matrice de distance, pour les clusters I ;
2. Dans la matrice de distance, recherchez la distance minimale $d(C_c, C_{c'}) = \min_{\substack{1 \leq p, q \leq I \\ p \neq q}} d(C_p, C_q)$,
où $d(.,.)$ est la fonction de distance que nous évoquons par la suite, et combinez cluster C_c et $C_{c'}$ pour former un nouvelle cluster $C_{cc'}$;
3. Mettre à jour la matrice de distance en calculant les distances entre le cluster $C_{cc'}$ et les autres clusters ;
4. Répétez les étapes 2 et 3 jusqu'à ce qu'il ne reste qu'un seul cluster.

La fusion d'une paire de clusters ou la formation d'un nouveau cluster dépend de la définition de la fonction de distance entre deux clusters. Il existe un grand nombre de définitions de fonctions de distance entre un cluster C_q et un nouveau cluster $C_{cc'}$ formé par la fusion de deux clusters C_c et $C_{c'}$. Dans ce qui suit, nous montrons brièvement quelques méthodes pour définir les fonctions de distance :

- *Méthode de liaison unique* (méthode du plus proche voisin) : la distance entre une paire de clusters est déterminée par les deux unités les plus proches des différents clusters. Le clustering à liaison unique a tendance à générer des clusters allongés, ce qui provoque l'effet de chaînage (Everitt et al., 2011). En conséquence, deux clusters aux propriétés assez différentes peuvent être connectés en raison de l'existence de bruit. Cependant, si les grappes sont éloignées les unes des autres, la méthode de liaison unique fonctionne bien.
- *Méthode de liaison complète* : contrairement au clustering à liaison unique, la méthode de liaison complète utilise la distance la plus éloignée d'une paire d'objets pour définir la distance inter-cluster.
- *Méthode de liaison de la moyenne de groupe* (moyenne de la méthode de groupe de paires non pondérée, c'est-à-dire UPGMA) : la distance entre deux grappes est définie comme la moyenne des distances entre toutes les paires de points de données, chacune provenant d'une grappe différente.

- *Méthode de liaison moyenne pondérée* (moyenne pondérée de la méthode du groupe de paires, c'est-à-dire WPGMA) : similaire à UPGMA, la liaison moyenne est également utilisée pour calculer la distance entre deux grappes. La différence est que les distances entre le cluster nouvellement formé et le reste sont pondérées en fonction du nombre de points de données dans chaque cluster.
- *Méthode de liaison centroïde* (centroïde de méthode de groupe de paires non pondérées, c'est-à-dire UPGMC) : deux clusters sont fusionnés en fonction de la distance de leurs centroïdes (moyennes).
- *Méthode de Ward* (méthode de la variance minimale) : le but de la méthode de Ward est de minimiser l'augmentation de ce que l'on appelle la somme intra-classe des erreurs au carré.

2.5.4 Résultats

Pour choisir la méthode de liaison la plus adéquate pour notre base de données, on utilise le coefficient d'agglomération, qui mesure la quantité de structure de regroupement trouvée (des valeurs plus proches de 1 suggèrent une forte structure de regroupement).

On souhaite choisir une méthode de liaison entre les 4 méthodes suivantes : average, single, complete, ward.

Cela nous permet de trouver certaines méthodes de clustering hiérarchiques qui peuvent identifier des structures de clustering plus fortes.

```
m <- c( "average", "single", "complete", "ward")
names(m) <- c( "average", "single", "complete", "ward")

ac <- function(x) {
  agnes(df, method = x)$ac

  map_dbl(m, ac)
  average    single    complete    ward
0.5850091 0.5113399 0.6886049 0.7978327
}
```

Ici, nous voyons que la méthode de Ward identifie la structure de clustering la plus forte des quatre méthodes évaluées. Donc, nous faisons notre classification à l'aide de la méthode Ward.




FIGURE 2.15 – Dendrogramme de la base de données

Comme toutes les méthodes de classifications, il faut avoir en tête un nombre de classes à faire. D'après les ABH – Moulouya, il y a 6 zones homogènes. Dans ce sens, nous essayerons de faire 6 classes.




FIGURE 2.16 – Classification de 6 groupes




FIGURE 2.17 – Scatter plot

Groupe 1	Groupe 2	Groupe 3	Groupe 4	Groupe 5	Groupe 6
DAR.DRIOUCH TLAT.AZLEF	SAFSAF BERKANE SLIMANIA.SMVA	LOUGGAGH EL.AOUIA TABOUAZANT	BGE.OUED.ZA GENFOUDA OUJDA.HAMRI OUJDA_dgm	TAOURIRT MELG.EL.OUIDANE OULED.LAFKIR A.P.SAKKA GUERCIF MELLOULOU	Belfarah A.B.MATHAR LAARICHAT MISSOUR TENDIT KSIBAT OUTAT.EL.HADJ BERKINE ANSEGMIR ZAIDA DELEG.MIDELT MIDELT_dgm

TABLE 2.5 – Stations par groupe

	TLAT.AZLEF	DAR.DRIOUCH	min	max
1	4.0	14.1	4.0	14.1
2	9.6	35.6	9.6	35.6
3	2.0	9.8	2.0	9.8
4	19.8	28.6	19.8	28.6
5	0.0	8.8	0.0	8.8
6	0.0	0.1	0.0	0.1
7	0.0	0.0	0.0	0.0
8	0.0	1.0	0.0	1.0
9	0.0	0.1	0.0	0.1
10	6.0	14.3	6.0	14.3

FIGURE 2.18 – Extrait des données du groupe 1 avec min et max

	SAFSAF	BERKANE	SLIMANIA.SMVA	min	max
1	12.0	35.6	26.200	12.0	35.600
2	11.6	17.1	15.700	11.6	17.100
3	3.4	24.1	23.000	3.4	24.100
4	59.2	87.9	91.300	59.2	91.300
5	1.9	17.0	19.000	1.9	19.000
6	0.0	1.9	1.700	0.0	1.900
7	0.0	0.0	1.119	0.0	1.119
8	7.6	4.9	3.700	3.7	7.600
9	0.0	3.6	2.400	0.0	3.600
10	10.5	29.9	34.100	10.5	34.100

FIGURE 2.19 – Extrait des données du groupe 2 avec min et max

	LOUGGAGH	EL.AOUIA	TABOUAZANT	min	max
1	23.7	6.3	30.515	6.3	30.515
2	20.5	30.6	31.000	20.5	31.000
3	2.3	2.0	8.800	2.0	8.800
4	32.0	18.5	67.800	18.5	67.800
5	51.0	15.0	42.600	15.0	51.000
6	13.9	21.0	28.600	13.9	28.600
7	0.0	1.0	1.700	0.0	1.700
8	40.6	30.7	21.300	21.3	40.600
9	22.1	13.1	8.800	8.8	22.100
10	33.6	0.0	10.700	0.0	33.600

FIGURE 2.20 – Extrait des données du groupe 3 avec min et max

	▲ BGE.OUED.ZA ▾	GENFOUDA ▾	OUJDA.HAMRI ▾	OUJDA_dgm ▾	min ▾	max ▾
1	16.200	25.100	13.6	19.8	13.6	25.100
2	9.300	17.100	13.7	12.3	9.3	17.100
3	11.700	15.700	19.3	25.6	11.7	25.600
4	30.100	33.700	69.3	73.2	30.1	73.200
5	5.400	35.100	29.9	21.6	5.4	35.100
6	2.718	0.000	0.7	0.9	0.0	2.718
7	0.000	0.000	0.0	0.0	0.0	0.000
8	15.313	10.000	1.9	9.7	1.9	15.313
9	0.000	0.000	0.0	1.2	0.0	1.200
10	21.200	16.200	24.9	34.2	16.2	34.200

FIGURE 2.21 – Extrait des données du groupe 4 avec min et max

▲	TAOURIRT ▾	MELG.EI.OUIDANE ▾		GUERCIF ▾	MELLOULOU ▾	min ▾	max ▾
1	17.2	11.9		8.338	9.6	8.33800e+00	17.200
2	10.7	3.2		17.783	20.4	3.20000e+00	20.400
3	7.1	0.0		1.857	0.3	0.00000e+00	7.100
4	42.7	44.4		25.730	24.2	2.38000e+01	44.400
5	2.4	8.5		5.550	6.8	2.40000e+00	8.500
6	0.3	0.0		0.699	0.0	0.00000e+00	0.699
7	0.0	0.0		0.165	0.0	0.00000e+00	0.165
8	7.6	33.6		13.214	14.2	5.20000e+00	43.700
9	0.0	1.4		0.846	0.0	0.00000e+00	1.400
10	7.2	2.2		3.223	1.4	0.00000e+00	7.200

FIGURE 2.22 – Extrait des données du groupe 5 avec min et max

	▲ Belfarah ▼	A.B.MATHAR ▼	LAARICHAT ▼		MIDELT_dgm ▼	min ▼	max ▼
1	18.5	11.2	4.4		10.7	0.0	19.700000
2	0.0	18.6	7.5		8.7	0.0	42.300000
3	19.7	3.9	0.3		2.6	0.0	19.700000
4	22.0	26.4	9.0		17.7	5.7	33.100000
5	9.6	10.8	53.8		36.1	0.0	53.800000
6	0.0	5.8	0.1		7.2	0.0	8.900000
7	0.0	0.0	0.0		0.0	0.0	3.500000
8	0.0	4.5	17.3		17.7	0.0	22.500000
9	0.0	0.0	0.1		5.4	0.0	9.500000
10	0.0	18.0	0.0		5.2	0.0	18.000000

FIGURE 2.23 – Extrait des données du groupe 6 avec min et max

Chapitre 3

Détection du changement climatique

Dans cette partie, nous considérons $\mathbf{x} = \{x_1, \dots, x_n\}$, ($n=480$) la série chronologique correspond aux précipitations mensuelles depuis janvier 1978 jusqu'au décembre 2017 de chaque station parmi les 30 stations.

3.1 Analyse des tendances

Les méthodes de détection de tendance testent généralement l'hypothèse nulle H_0 - où les données sont classées de manière indépendante et aléatoire de sorte qu'il n'y a pas de tendance particulière dans les données - par rapport à l'hypothèse alternative H_1 d'une tendance monotone dans les données existantes.

3.1.1 Tests classiques utilisés

3.1.1.1 Mann-Kendall

La statistique de test du test de tendance de Mann - Kendall est de la forme

$$S_{mk} = \sum_{i=1}^{n-1} \sum_{j=i+1}^n \text{sgn}\{x_j - x_i\},$$

Où

$$\text{sgn}\{x_j - x_i\} = \begin{cases} 1, & x_j - x_i > 0, \\ 0, & x_j - x_i = 0, \\ -1, & x_j - x_i < 0. \end{cases}$$

La statistique de test S_{mk} est asymptotiquement distribuée normalement et, sous l'hypothèse nulle, elle a une espérance $E[S_{mk}] = 0$ et une variance $Var[S_{mk}] = \frac{n(n-1)(2n+5)}{18}$ lorsqu'il n'y a pas de liens dans les données. Pour n petit, l'utilisation de la statistique de test standardisée $Z_{mk} = \frac{S_{mk}}{\sqrt{Var[S_{mk}]}}$ est commun, car il fournit une bonne approximation de la distribution normale. La p-value approximative d'un tel test est alors calculée comme

$$p_{mk} = 2\min(0.5, P(X > |Z_{mk}|)), \quad X \sim N(0, 1).$$

La p-value sera ensuite comparée à un niveau de signification présélectionné $0 < \alpha < 1$. Si $p_{mk} < \alpha$ nous acceptons l'existence d'une tendance en x . En regardant plus près de la formule de la statistique S_{mk} nous voyons que ce test compare en fait chaque point

de données x_i à tous les points de données apparus ultérieurement. Ainsi, par exemple, lorsque la séquence x montre une tendance à la hausse, la statistique de test a une valeur plus grande (et par conséquent une p-value plus petite) par rapport à une situation dans laquelle les points de données x_i sont ordonnés de manière aléatoire et indépendante. De plus, une valeur positive de S_{mk} signifie que les points de données x_i augmentent avec le temps, tandis qu'une valeur négative de S_{mk} indique que x_i diminue avec le temps. Le test de tendance de Mann-Kendall a été jusqu'à présent la méthode la plus courante de détection de tendance et il est largement utilisé dans la littérature. De plus, il existe une version multivariée de Mann-Kendall qui peut être appliquée à plusieurs ensembles de données chronologiques de même taille à la fois. Cependant, cela indique seulement s'il existe au moins un ensemble avec une tendance qui peut dominer les autres, sans identifier où la dominance se produit.

3.1.1.2 Cox–Stuart

Le test de Cox-Stuart est un test de signe non paramétrique permettant de détecter une tendance dans des données indépendantes ordonnées dans le temps. La statistique de test est donnée par

$$Z_{cs} = \frac{|S_{sc} - n/6|}{\sqrt{n/12}}$$

Où S_{sc} désigne le nombre maximum de signes calculé comme suit.

$$S_{cs} = \max_j \left\{ \sum_{i=1}^{[n/3]} \mathbf{1} [sgn \{x_{n-[n/3]+1} - x_i\} = j], j = -1, 0, 1 \right\},$$

Où $[n/3]$ est le plus petit entier supérieur à $n/3$, et $\mathbf{1}[\cdot]$ est la mesure de Dirac. Cette statistique de test est en fait basée sur une comparaison par paires entre le premier et le dernier tiers de données. La statistique de test suit, asymptotiquement, une distribution normale, et on sait qu'elle a une puissance inférieure à celle du test de Mann-Kendall.

3.1.2 Résultats

Comme Cox–Stuart a une puissance inférieure à celle de Mann-Kendall, on utilise ce dernier pour nos données.

Stations	p-value	signe S
A.B.MATHAR	0.0002836	Positif
ANSEGMIR	0.1249	Positif
A.P.SAKKA	0.0528	Positif
BERKANE	0.3203	Positif
BERKINE	0.1486	Positif
BGE.OUED.ZA	0.06493	Positif
Belfarah	0.1596	Positif
DAR.DRIOUCH	0.07754	Positif
DELEG.MIDELT	0.8948	Négatif
EL.AOUIA	1.582e-05	Positif
GENFOUDA	0.2255	Positif
GUERCIF	0.4023	Positif
KSIBAT	0.05708	Positif
LAARICHAT	0.4231	Positif
LOUGGAGH	0.1677	Positif
MELG.El.OUIDANE	0.13	Positif
MELLOULOU	0.1014	Positif
MIDELT_dgm	0.02613	Positif
MISSOUR	0.05287	Positif
OUJDA.HAMRI	0.08687	Positif
OUJDA_dgm	0.4875	Positif
OULED.LAFKIR	0.8266	Négatif
OUTAT.EL.HADJ	0.2504	Positif
SAFSAF	0.04734	Positif
SLIMANIA.SMVA	0.4114	Positif
TABOUAZANT	0.9235	Positif
TAOURIRT	0.6382	Positif
TENDIT	0.03063	Positif
TLAT.AZLEF	0.04496	Positif
ZAIDA	0.4286	Positif

TABLE 3.1 – Résultats Test Mann-Mendall

Commentaires : En fixant un niveau de signification $\alpha = 0.05$, nous remarquons que la majorité de stations ne possèdent pas une tendance.

Ainsi, l'analyse de tendance nous ne permet pas de conclure quant à l'existence d'un changement climatique au cours des 40 ans dans le bassin Moulouya.

Par la suite, nous allons analyser les ruptures dans les séries chronologiques des précipitations des différentes stations pour détecter des points de changement dans ces séries.

3.2 Analyse des ruptures

Une rupture est définie comme changement, dans une série temporelle, dans le comportement des données à partir d'un certain point. La majeure partie du temps, la moyenne des données avant et après la rupture ne seront pas les mêmes. Cela s'appelle une rupture

abrupte. Certaines ruptures se passent en deux points où il y a une transition entre ceux-ci. Dans d'autres cas, une tendance apparaît après la rupture, d'où le nom de déclenchement de tendance. Dans cette partie nous nous intéressons particulièrement aux ruptures abruptes, au déclenchement de tendance et aux tendances.

3.2.1 Tests classiques utilisés

3.2.1.1 Pettitt's Test

Le test de Pettitt est un test de signe non paramétrique basé sur le test à deux échantillons de Mann-Whitney (basé sur le rang), et sa statistique de test est de la forme

$$S_p = \max_k \left| \sum_{i=1}^k \sum_{j=i+1}^n \text{sgn}\{x_i - x_j\} \right|, 1 < k < n.$$

Sous l'hypothèse nulle et pour chaque k , la distribution de S_p est symétrique autour de zéro avec $E[S_p] = 0$. On s'attend à ce que S_p ait de grandes valeurs lorsqu'il y a un décalage dans les données. En considérant des observations continues, on a alors

$$\sum_{i=1}^k \sum_{j=i+1}^n \text{sgn}\{x_i - x_j\} = 2 \sum_{i=1}^k r_i - k(n+1), \quad 1 < k < n,$$

Où r_i est le rang correspondant du point de données x_i . La p-value approximative du test de Pettitt est

$$p_p = 2 \exp \left\{ \frac{-6S_p^2}{n^2 + n^3} \right\}$$

et la valeur de k fournie est considérée comme le point de changement le plus probable.

3.2.1.2 Buishand Test

Les tests de Buishand supposent que x provient d'une distribution normale de moyenne μ et de variance connue σ^2 . En supposant un changement de la moyenne au temps k , on peut alors écrire

$$x_i = \begin{cases} \mu + \epsilon_i, & i = 1, \dots, k, \\ \mu + \Delta + \epsilon_i, & i = k+1, \dots, n, \end{cases}$$

Où ϵ_i est une variable distribuée normale à moyenne nulle, et $\Delta \neq 0$ est la grandeur qui décale la moyenne des données après le temps k . En d'autres termes, les tests de Buishand supposent qu'il y a un saut dans la moyenne des données à partir du temps k . Il existe deux types de tests de ce type : Buishand Range et Buishand U. La statistique de test de la gamme Buishand est

$$S_b = \frac{\max_k D_k - \min_k D_k}{\sigma \sqrt{n}},$$

Où

$$D_k = \sum_{i=1}^k (x_i - \bar{x}), \quad 1 < k < n,$$

et $\bar{x}$ est la moyenne de x . La statistique de test du test Buishand U est

$$S_u = \frac{1}{n(n+1)} \sum_{k=1}^{n-1} \left[\frac{D_k}{\sqrt{n^{-1} \sum_{j=1}^n (x_j - \bar{x})^2}} \right]^2$$

3.2.2 Résultats

Les séries qu'on travaille sur sont les observations journalières des précipitation dans les 30 stations, ainsi les valeurs possible des ces obseravtion ne peuvent être négatives.

Donc, on ne peut pas appliquer le test de Buishand qui suppose la normalité de la série (comme la majorité de tests). Le test de Pettitt nous apparait adéquat dans ce cas, même s'il ne donne qu'un seul point de changement. Ainsi, les résultats suivant sont ceux du test de Pettitt.

Stations	U*	p-value	Date du changement
A.B.MATHAR	12354	0.0005158	juil-2001
ANSEGMIR	7225	0.1185	juil-2005
A.P.SAKKA	7102	0.1303	sept-1988
BERKANE	5614	0.3631	sept-2002
BERKINE	7333	0.1088	déc-1984
BGE.OUED.ZA	7908	0.0677	août-2005
Belfarah	5958	0.2927	août-2013
DAR.DRIOUCH	6474	0.2068	sept-1988
DELEG.MIDELT	3515	1	déc-1984
EL.AOUIA	13782	6.837e-05	févr-1995
GENFOUDA	6359	0.224	août-2008
GUERCIF	381	0.7075	oct-1985
KSIBAT	8559	0.03789	juil-2001
LAARICHAT	5347	0.4254	mars-1989
LOUGGAGH	8108	0.05692	août-1987
MELG.EL.OUIDANE	6628	0.1854	sept-1988
MELLOULOU	6643	0.1834	août-1989
MIDELT_dgm	6810	0.1624	juil-2001
MISSOUR	7306	0.1112	avr-1989
OUJDA.HAMRI	7537	0.09233	août-2008
OUJDA_dgm	3508	1	sept-2001
OULED.LAFKIR	4807	0.5724	mars-1994
OUTAT.EL.HADJ	6128	0.2619	déc-1984
SAFSAF	7259	0.1154	sept-1988
SLIMANIA.SMVA	4136	0.7921	août-2001
TABOUAZANT	3237	1	juin-2011
TAOURIRT	4387	0.7055	sept-2002
TENDIT	9524	0.01473	sept-2005
TLAT.AZLEF	8714	0.03278	oct-1985
ZAIDA	4691	0.6076	juil-2005

TABLE 3.2 – Résultats du test de Pettitt

Commentaires : Nous pouvons conclure que la majorité des changements possibles donnés par le test de Pettitt sont vécus au cours de la période entre les deux périodes suivantes : 1984-1989 et 2000-2005. Plus de 80% des points de changement sont survenus lors de ces deux périodes.

Malheureusement, la p-value du test, dans la majorité des stations, ne nous permet pas de prendre en considération de l'existence des ces points de changements.

Encore une fois, l'analyse de la rupture ne nous permet pas de conclure quant à l'existence d'un changement climatique dans le bassin Moulouya au cours des 40 ans étudiés.

Nous essayons par la suite de faire une projection des séries des observations des précipitations mensuelles dans les 30 stations.

3.3 Analyse des projections future

Dans ce chapitre nous allons présenter des visualisations des séries, mais nous allons mettre juste un échantillon des figures de quelques stations car elles sont nombreuses, Nous vous laissons le lien de NoteBook Jupyter pour voir les résultats et les codes en entier.

On considère la base de données comme un ensemble des séries temporelles, chaque série temporelle correspond à une station parmi les 30 stations de l'étude.

3.3.0.1 Visualisation de la série de quelques stations




FIGURE 3.1 – précipitation extrême en octobre 2008





FIGURE 3.2 – précipitation extrême en mars 2004

Ces visualisations donnent une idée générale sur les séries mais ne répondent pas à la fameuse question : la série est-elle stationnaire ?

3.3.1 L'évolution des précipitations durant toute la période en faisant la moyenne et la variance sur chaque année

(voir les autres figures sur Notebook)



Un processus est dit stationnaire si ses grandeurs caractéristiques (moyenne, variance) ne varient pas au cours du temps. C'est une propriété importante que doit vérifier les séries temporelles.

Mais on peut pas décider sur la stationnarité seulement avec ces figures. Donc il nous faut un test.

3.3.1.1 Décomposition des séries chronologiques


Une série temporelle peut être décomposée en 3 composantes :

Tendance : Mouvement de hausse et de baisse des données au cours du temps sur une longue période (par exemple le prix de l'immobilier).

Saisonnalité : Variance saisonnière (par exemple une augmentation de la demande de glace pendant l'été).

Bruit : Des pics et des creux à intervalles aléatoires.





3.3.2 surapprentissage

Comme nous l'avons vu, l'entraînement d'un modèle revient à mesurer l'erreur de la sortie de l'algorithme avec les données d'exemple et chercher à la minimiser.

Un premier piège à éviter est donc d'évaluer la qualité de votre modèle final à l'aide des mêmes données qui ont servi pour l'entraînement. En effet, le modèle est complètement optimisé pour les données à l'aide desquelles il a été créé. L'erreur sera précisément minimum sur ces données. Alors que l'erreur sera toujours plus élevée sur des données que le modèle n'aura jamais vues !

Pour minimiser ce problème, la meilleure approche est de séparer dès le départ notre jeu de données en deux parties distinctes :

- Le training set, qui va nous permettre d'entraîner notre modèle et sera utilisé par l'algorithme d'apprentissage. C'est celui dont on a parlé depuis le début.
- Le testing set, qui permet de mesurer l'erreur du modèle final sur des données qu'il n'a jamais vues. On va simplement passer ces données comme s'il s'agissait de données que l'on n'a encore jamais rencontrées (comme cela va se passer ensuite en pratique pour prédire de nouvelles données) et mesurer la performance de notre modèle sur ces données. On appelle aussi cela held-out data, pour souligner que ce sont des données auxquelles on ne va pas toucher avant la toute fin pour pouvoir être bien sûr que le modèle fonctionne.

Pour lutter contre ce problème, on partage des données en deux parties :

- 80% des données d'entraînement : de 1978 jusqu'à 2010.

	TLAT.AZLEF	DAR.DRIOUCH	SAFSAF	BERKANE	SLIMANIA.SMVA	LOUGGAGH	ELAOUIA	TABOUAZANT	BGE.OUED.ZA	GENFOUDA	...	LAARICHAT
date												
1978-01-01	4.0	14.1	12.000	35.6	26.2	23.7	6.3	30.515	16.2	25.1	...	4.4
1978-02-01	9.6	35.6	11.600	17.1	15.7	20.5	30.6	31.000	9.3	17.1	...	7.5
1978-03-01	2.0	9.8	3.400	24.1	23.0	2.3	2.0	8.800	11.7	15.7	...	0.3
1978-04-01	19.8	28.6	59.200	87.9	91.3	32.0	18.5	67.800	30.1	33.7	...	9.0
1978-05-01	0.0	8.8	1.900	17.0	19.0	51.0	15.0	42.600	5.4	35.1	...	53.8
...	...	...	...	...	...	...	...	...	...	...	...	...
2009-08-01	0.0	0.0	0.000	0.0	0.0	5.7	1.5	3.500	0.0	0.0	...	0.0
2009-09-01	59.0	62.5	46.126	0.0	62.7	147.4	172.6	101.900	34.1	53.3	...	60.5
2009-10-01	4.2	1.9	0.600	1.0	0.0	1.1	4.5	2.800	0.0	0.0	...	0.0
2009-11-01	8.5	20.0	10.900	20.5	20.0	9.3	6.5	6.500	11.3	14.8	...	0.0
2009-12-01	26.8	27.2	34.300	35.0	39.1	13.2	48.1	24.000	32.4	22.4	...	0.0

384 rows x 30 columns

FIGURE 3.3 – Extrait des données d'entraînement

— 20% des données de test : de 2010 jusqu'à 2018.

	TLAT.AZLEF	DAR.DRIOUCH	SAFSAF	BERKANE	SLIMANIA.SMVA	LOUGGAGH	ELAOUIA	TABOUAZANT	BGE.OUED.ZA	GENFOUDA	...	LAARICHAT
date												
2010-01-01	87.3	64.6	202.400	201.200	221.800	57.7	60.0	76.5	42.4	46.1	...	6.5
2010-02-01	34.0	25.3	29.900	37.200	35.700	65.1	90.4	43.1	32.1	25.0	...	3.0
2010-03-01	44.7	68.0	87.300	71.300	73.500	97.8	72.4	55.7	63.1	91.0	...	14.0
2010-04-01	104.8	103.4	39.400	71.800	55.900	67.9	81.9	37.9	57.4	56.7	...	10.5
2010-05-01	0.1	4.8	6.400	13.500	5.200	20.6	9.0	31.1	13.1	18.7	...	7.0
...	...	...	...	...	...	...	...	...	...	...	...	...
2017-08-01	52.6	24.9	16.500	12.500	18.900	54.6	79.5	44.6	11.8	7.8	...	40.2
2017-09-01	0.8	2.1	0.000	2.000	3.600	14.6	20.5	2.6	10.2	5.6	...	0.0
2017-10-01	2.1	5.5	8.588	13.743	11.793	12.8	8.5	6.2	6.6	9.4	...	0.0
2017-11-01	53.5	12.7	18.100	33.100	20.200	3.7	7.5	0.0	13.0	28.2	...	0.0
2017-12-01	19.8	15.6	17.200	30.200	60.400	0.4	11.5	9.9	14.6	28.1	...	3.9

96 rows x 30 columns

FIGURE 3.4 – Extrait des données de test



un échantillon de Visualisation des données d'entraînement et des données de test de chaque série chronologiques.

3.3.3 Définition de la non stationnarité

La plupart des séries économiques sont non stationnaires, c'est-à-dire que le processus qui les décrit ne vérifie pas au moins une des conditions de la définition d'un processus stationnaire du second ordre, donnée par :

- $E(Y_t) = m$ indépendant du temps
- $V(Y_t) = \gamma(0) < \infty, \gamma(0)$ indépendant du temps.
- $\text{Cov}(Y_t, Y_{th}) = \gamma(h)$ ne dépend pas de t .

Ceci nous conduit à définir deux types de non stationnarité selon la condition portant sur le moment d'ordre 1 qui n'est pas vérifiée (**non stationnarité déterministe**) ou les conditions portant sur les moments du second ordre qui ne sont pas vérifiées (**non stationnarité stochastique**).

Le test KPSS pour détecter la non stationnarité déterministe. **Le test ADF** pour détecter la non stationnarité stochastique.

3.3.4 Test de stationnarité

Test Dickey-Fuller simple Les modèles servant de base à la construction de ces tests sont au nombre de trois le modèle sans constante, le modèle avec constante et le modèle avec constante et tendance.

Le principe des tests est simple : si l'hypothèse $H_0 : \varphi_1 = 1$ est retenue dans l'un de ces trois modèles, le processus est alors non stationnaire.

$$\begin{aligned} [1] \quad y_t &= \varphi_1 y_{t-1} + \epsilon_t \\ [2] \quad y_t &= \varphi_1 y_{t-1} + \beta + \epsilon_t \\ [2] \quad y_t &= \varphi_1 y_{t-1} + bt + c + \epsilon_t \end{aligned}$$

Si l'hypothèse H_0 est vérifiée, la chronique y_t n'est pas stationnaire quel que soit le modèle retenu.

Dans le dernier modèle [3], si on accepte $H_1 : \varphi_1 < 1$ et si le coefficient b est significativement différent de 0, alors le processus est un processus TS ; on peut le rendre stationnaire en calculant les résidus par rapport à la tendance estimée par les moindres carrés ordinaires.

Sous H_0 , les règles habituelles de l'inférence statistique ne peuvent pas être appliquées pour tester cette hypothèse, en particulier la distribution de Student du paramètre φ_1 ; Dickey et Fuller ont donc étudié la distribution asymptotique de l'estimateur φ_1 sous l'hypothèse H_0 . À l'aide de simulations de Monte-Carlo, ils ont tabulé les valeurs critiques pour des échantillons de tailles différentes. Ces tables sont des tables analogues aux tables du t de Student. Les auteurs ont choisi de tester la valeur $(\hat{\varphi}_1 - 1)$ au lieu de $\hat{\varphi}_1$ pour des raisons purement statistiques.

Cela n'est pas gênant pour le test. En effet, $y_t = \varphi_1 y_{t-1} + \epsilon_t$ s'écrit aussi :

$$y_t - y_{t-1} = \varphi_1 y_{t-1} - y_{t-1} + \epsilon_t$$

$$y_t = (\varphi_1 - 1)y_{t-1} + \epsilon_t$$

Il est donc équivalent de tester comme hypothèse $H_0 : \varphi_1 = 1$ ou $\varphi_1 - 1 = 0$. Les principes généraux du test sont les suivants :

On estime par les moindres carrés ordinaires le paramètre φ_1 noté $\hat{\varphi}_1$ pour les modèles [1], [2] et [3]. L'estimation des coefficients et des écarts types du modèle par les moindres carrés ordinaires fournit t_1 qui est analogue à la statistique de Student (rapport du coefficient sur son écart type). Si $t_{\varphi_1} > t_{tabule}$, alors on accepte l'hypothèse H_0 ; il existe une racine unité, le processus n'est donc pas stationnaire.

3.3.5 Dickey-Fuller augmenté

Les tests de Dickey Fuller simples reposent sur l'hypothèse que les résidus sont des bruits blancs, or il n'y a aucune raison pour que, a priori, l'erreur soit non corrélée ; on appelle tests de Dickey-Fuller augmentés (ADF) la prise en compte de cette hypothèse.

Les tests ADF sont fondés sous l'hypothèse alternative $|\phi_1| < 1$, sur l'estimation par les MCO des trois modèles :

$$Model\ 1 : \Delta y_t = \rho y_{t-1} + \sum_{j=2}^p \varphi_j \Delta y_{t-j+1} + \epsilon_t$$

$$Model\ 2 : \Delta y_t = \rho y_{t-1} + c + \sum_{j=2}^p \varphi_j \Delta y_{t-j+1} + \epsilon_t$$

$$Model\ 2 : \Delta y_t = \rho y_{t-1} + c + bt + \sum_{j=2}^p \varphi_j \Delta y_{t-j+1} + \epsilon_t$$

Avec $\epsilon \rightarrow iid$

Le test se déroule de manière similaire aux tests DF simples, seules les tables statistiques diffèrent. La valeur de p peut être déterminée selon les critères Akaike ou de Schwarz, ou encore, en partant d'une valeur suffisamment importante de p , on estime un modèle à $p - 1$ retard, puis à $p - 2$ retard, jusqu'à ce que le coefficient du p_{ieme} retard soit significatif.

3.3.6 Application sur les séries chronologiques :

Maintenant, utilisons le même ensemble de données et testons-le à l'aide de la fonction statistique `adfuller()` fournie par le package de modèle `stats`, pour vérifier si les données sont stationnaires ou non.

Station	p-value	interprétation
TLAT.AZLEF	1.550179015050069e-18	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
DAR.DRIOUCH	5.644664848850111e-09	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
SAFSAF	0.001161144068736008	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
BERKANE	6.440437282585537e-05	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
SLIMANIA.SMVA	2.7286151389345788e-05	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
LOUGGAGH	0.0	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
EL.AOUIA	1.6569376337502343e-28	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
TABOUAZANT	0.0	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
BGE.OUED.ZA	2.917874399483112e-30	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
GENFOUDA	6.86671567995591e-05	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
OUJDA.HAMRI	7.00363365708017e-06	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
OUJDA_dgm	3.1490193235247544e-05	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
TAOURIRT	1.824208520510019e-05	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
MELG.EL.OUIDANE	0.003690902689172518	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
OULED.LAFKIR	6.717754379453548e-30	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
A.P.SAKKA	3.564486113959127e-08	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
GUERCIF	0.0	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
MELLOULOU	0.00429647838346333	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
Belfarah	1.6421899087240103e-08	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
A.B.MATHAR	2.085192041437193e-30	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
LAARICHAT	0.007936771892362518	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
MISSOUR	4.536886277849e-06	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
TENDIT	5.807816928174007e-25	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
KSIBAT	5.040525823985524e-07	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
OUTAT.EL.HADJ	6.380042490804738e-24	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
BERKINE	0.0	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
ANSEGMIR	0.0	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
ZAIDA	0.0	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
DELEG.MIDELT	0.009316465648369096	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%
MIDELT_dgm	0.0	P-value est <0.05 ,On rejette H0, donc les données de la série chronologique sont stationnaires à 95%

Commentaire : On remarque que toutes les séries sont stationnaires, donc on aura pas besoin de différencier les séries pour obtenir la stationnarité.

3.3.7 Autocorrélation

Une fois obtenue la stationnarité de la série, l'étape suivante consiste à analyser le graphe de la fonction d'autocorrélation (FAC) et celui de la fonction d'autocorrélation partielle (FAP) afin de déterminer les paramètres (p,q) du modèle.

Les corrélogrammes, graphes de la fonction d'autocorrélation et de la fonction d'autocorrélation partielle permettent selon leurs aspects d'identifier correctement les paramètres p et q dont les valeurs n'excèdent pas deux en règle générale : $p \in \{0, 1, 2\}$ et $q \in \{0, 1, 2\}$.

La fonction d'autocorrélation, notée (FAC), est constituée par l'ensemble des autocorrélations, $\rho_k = corr(Y_t, Y_{t-k})$ de la série calculées pour des décalages d'ordre k, $k \in \{1, \dots, K\}$. Le décalage maximum K admissible pour que le coefficient d'autocorrélation ait un sens se situe en général entre $\frac{n}{3} \leq K \leq \frac{n}{6}$ où (n) est le nombre d'observations temporelles. Pour $n \geq 150$ on prendra $K = \frac{n}{5}$.

Le coefficient d'autocorrélation d'ordre k, ρ_k , peut être estimé par :

$$r_k = \frac{\sum_{t=k+1}^n (y_t - \bar{y}_1)(y_{t+k} - \bar{y}_2)}{\sqrt{\sum_{t=k+1}^n (y_t - \bar{y}_1)^2 \sum_{t=k+1}^n (y_{t+k} - \bar{y}_2)^2}}$$

Avec $\bar{y}_1 = \frac{1}{n-k} \sum_{t=k+1}^n y_t$ et $\bar{y}_2 = \frac{1}{n-k} \sum_{t=k+1}^n y_{t-k}$.

Sous l'hypothèse $H_0 : \rho_k = 0$, la statistique $t_c = \frac{|r_k|}{\sqrt{1-r_k^2}}$ suit une loi de Student à (n-2) degrés de libertés. Si la valeur calculée t_c est supérieure au quantile $\frac{\alpha}{2}$ d'une loi de Student


à $(n-2)$ degrés de liberté $t_c \geq t_{n-2}^{\frac{\alpha}{2}}$, alors l'hypothèse H_0 est rejetée au seuil (test bilatéral).

La fonction d'autocorrélation partielle, notée (FAP), est constituée par l'ensemble des autocorrélations partielles, le coefficient d'autocorrélation partielle mesurant la corrélation entre les variables entre Y_t et Y_{t-k} , l'influence de la variable Y_{t-k-i} étant contrôlée pour $i < k$.

Outre les coefficients de corrélation, les corrélogrammes affichent les intervalles de confiance à 95%, qui permettent de déterminer quels sont les coefficients statistiquement significatifs à prendre en compte.

L'interprétation des corrélogrammes pour la spécification des processus AR et MA est généralement gouvernée par les règles suivantes :

- les processus autorégressifs d'ordre p , $AR(p)$, présentent une fonction d'autocorrélation dont les valeurs décroissent exponentiellement avec des alternances possibles de valeurs positives et négatives ; leur fonction d'autocorrélation partielle présente exactement p pics aux p premières valeurs du corrélogramme d'autocorrélation partielle ;
- les processus de moyenne mobile d'ordre q , $MA(q)$, présentent exactement q pics aux q premières valeurs du corrélogramme de la fonction d'autocorrélation et des valeurs exponentiellement décroissantes de la fonction d'autocorrélation partielle ;
- si la fonction d'autocorrélation décroît trop lentement, on conseille de différencier la série avant l'identification du modèle ;
- les processus mixtes de type ARMA peuvent présenter des graphes d'autocorrélation et d'autocorrélation partielle plus complexes à interpréter et nécessiter plusieurs itérations de type identification-estimation-diagnostic.



Commentaire : On constate que les autocorrélogrammes ne décroissent pas rapidement, donc ça confirme la stationnarité des séries.

3.3.7.1 Analyse des autocorrélations :

Nous pouvons utiliser le PACF pour déterminer le nombre optimal de termes à utiliser dans le modèle AR. Le nombre de termes détermine l'ordre du modèle. Et l'ACF peut être utilisé pour déterminer le meilleur ordre du modèle MA.

Prenons un exemple de ls deux premières stations :

(Rappelons que le PACF peut être utilisé pour déterminer le meilleur ordre du modèle AR. Les lignes bleues horizontales en pointillés représentent les seuils de signification. Les lignes verticales représentent les valeurs de l'ACF et du PACF à un moment donné. Seules les lignes verticales qui dépassent les lignes horizontales sont considérées comme significatives.)

Station 1 : nous pouvons créer et ajuster un modèle ARMA avec un AR d'ordre 1, et un MA d'ordre 0 :

A l'aide de la bibliothèque statsmodels.tsa.arima-model sur python, on trouve les coefficients du modèle ARMA.

```
print(arma.params)

const      21.393057
ar.L1      0.123071
ar.L2      -0.064765
sigma2     1022.933179
dtype: float64
```

FIGURE 3.5 – Les coefficients du modèle ARMA, TLAT.AZLEF

Station 2 : nous pouvons créer et ajuster un modèle ARMA avec un AR d'ordre 1, et un MA d'ordre 3 :

```
print(arma_ar2.params)

const      19.837893
ar.L1      0.734986
ar.L2      0.716013
ar.L3      -0.992402
ma.L1      -0.722346
ma.L2      -0.723463
ma.L3      0.987541
sigma2     756.963601
dtype: float64
```

FIGURE 3.6 – Les coefficients du modèle ARMA, DAR.DRIOUCH

Et on répète la même logique pour toute les séries chronologiques.

3.3.8 Prédiction

3.3.8.1 Rappel sur les modèles AR, MA, ARMA, ARIMA

Le processus AR : Le processus AR signifie autorégressif. Concrètement, si l'on considère un processus stationnaire X_t , on considère qu'il est autorégressif d'ordre p si l'on peut expliquer sa valeur à l'instant T en utilisant ses p termes précédents.

Mathématiquement, cela signifie que :

$$\forall t ; X_t = \sum_{i=1}^p \alpha_i X_{t-i} + \epsilon_t$$

avec ϵ l'erreur et $(\alpha_1, \alpha_2, \dots, \alpha_p)$ des réels.

Le processus MA : MA signifie 'moving average' ou en français moyenne mobile.

Soit X_t une série temporelle, on considère que c'est un processus MA d'ordre p si on peut exprimer sa valeur à l'instant t comme une combinaison linéaire d'erreur aléatoires (bruit blanc).

Mathématiquement on traduit cela par :

$$\forall t ; X_t = \epsilon_t + \sum_{i=1}^p \alpha_i \epsilon_{t-i}$$

avec ϵ l'erreur et $(\alpha_1, \alpha_2, \dots, \alpha_p)$ des réels. Le processus ARMA : Comme vous vous en doutez, le modèle ARMA est tout simplement une combinaison d'un processus AR et d'un processus MA. Cela permet de modéliser des séries temporelles plus complexes.

Un modèle ARMA d'ordre (p,q) s'écrit donc sous la forme :

$$\forall t ; X_t = \sum_{i=1}^p \alpha_i X_{t-i} + \epsilon_t + \sum_{i=1}^q \beta_i \epsilon_{t-i}$$

Avec $(\alpha_1, \alpha_2, \dots, \alpha_p)$ et $(\beta_1, \beta_2, \dots, \beta_q)$

Cependant, l'une des limitations de ce modèle est qu'il ne peut modéliser que des séries temporelles stationnaires.

Ainsi, il ne peut modéliser une série temporelle avec une tendance linéaire croissante. C'est pour pallier ce problème que le modèle ARIMA a été développé.

Le modèle ARIMA : Le I du modèle ARIMA signifie 'integrated' pour intégration. En différenciant les séries temporelles, il est possible de retirer les tendances qu'elles présentent pour les stationnariser.

Prenons l'exemple d'une série temporelle avec une tendance linéaire de la forme :

$$X_t = \alpha + \beta t + \epsilon_t$$

$$X_t - X_{t-1} = \beta + \epsilon_t - \epsilon_{t-1}$$

Ainsi en différenciant la série une fois, la dépendance temporelle linéaire est éliminée et la différence est stationnaire.

De la même façon, une tendance quadratique peut être éliminée en différenciant la série deux fois.

Une fois la série stationnarisée, il est alors possible d'appliquer le modèle **ARMA**.

Le modèle ARIMA est donc une combinaison de ce processus de différenciation et du processus ARMA classique.

Par ailleurs, si la série temporelle présente à la fois une tendance et une saisonnalité, il est possible d'utiliser le modèle **SARIMA** qui est un modèle ARIMA prenant aussi en compte une composante saisonnière.

Donc la seule question à poser, quel modèle est adéquat à nos séries chronologiques, et avec quels paramètres ?

Nous avons trouvé dans les précédentes parties qu'il n'y a pas de tendance et toutes les séries sont stationnaires. Alors le meilleur modèle est **ARMA**.

Pour trouver les paramètres, on fait appel à bibliothèque statsmodels de Python qui arrive à choisir les meilleurs paramètres pour un meilleur modèle.

Le modèle ARIMA avec Python donne la possibilité de faire des prévisions basées sur des observations historiques, ce qui crée un avantage concurrentiel. Par exemple, si une organisation a la capacité de mieux prévoir les quantités vendues d'un produit, elle sera dans une position plus favorable pour optimiser les niveaux de stock. Cela peut se traduire par une augmentation des liquidités des réserves de trésorerie de l'organisation, une diminution du fonds de roulement et une amélioration de la satisfaction des clients en réduisant l'arriéré des commandes.

Nous allons créer le modèle, en se basant sur l'apprentissage des données et leurs évaluation avec des tests.

NB : cette étape de recherche de meilleure modèle est faite avec les données d'entraînement (Train Data)

3.3.8.2 Évaluation

Maintenant que le modèle a été adapté aux données d'entraînement, nous pouvons prévoir l'avenir. Rappelez-vous que notre ensemble de données de test va du 01-01-2010 au 01-12-2017. Donc, si nous vérifions la longueur de nos données de test, nous obtenons 37 lignes ou 96 périodes. C'est la valeur que nous utiliserons pour notre appel de méthode `.predict()`.

Nous pouvons ensuite tracer les données d'origine et prévisions futures trouvées pour voir dans quelle mesure nos prévisions de prédiction correspondent à l'ensemble de test pour lequel nous avons les données réelles :

- TLAT.AZLEF DAR.DRIOUCH (0,882)
- SAFSAF BERKANE (0,902)
- BERKANE SLIMANIA.SMVA (0,949)
- GENFOUDA OUJDA.HAMRI (0,88)
- ...




FIGURE 3.8 – Matrice de corrélation entre les précipitations des stations d'étude

Pour valoriser cette corrélation, on peut s'ouvrir sur une analyse des séries chronologiques avancées (les modèle Vars)

Chapitre 4

Conclusion

En guise de conclusion, nous avons bel et bien constaté à l'aide des statistiques descriptives faites que le caractère méditerranéen du climat est très présent dans le bassin. En effet, entre 70-80% des pluies tombent entre les mois de décembre et de mai. Cela n'empêche pas l'existence de plusieurs groupes au sein du même bassin.

Dans ce sens, nous avons essayé de visualiser la segmentation du bassin en utilisant les précipitations de nos données. Une étude qui nous a permis de constater que cette segmentation était bien adaptée puisque les régions proches étaient, plus au moins, dans les mêmes groupes. D'où l'impact direct de la zone géographique sur le climat des régions.

Pour détecter un changement climatique possible, nous avons suivi plusieurs démarches à savoir la détection des points de changement et la tendance ainsi que des projections futures. Au contraire de tout ce qu'on attendait, les résultats de toutes ces analyses confirment la non-existence d'un changement climatique dans le bassin de Moulouya. En effet, les précipitations mensuelles au cours des 40 ans ne permettent pas de prouver l'existence d'un changement climatique.

Une expansion des années d'étude ainsi que l'ajout de d'autres données (température, niveau eau souterrains et de surface) seront d'une grande importance pour toute nouvelle étude dans ce sens.

Annexe A

Lien du pdf de l'annexe

[click here](#)

Bibliographie

- [1] Acharki, S., Amharref, M., El Halimi, R. Bernoussi, A.-S. : *Évaluation par approche statistique de l'impact des changements climatiques sur les ressources en eau : application au périmètre du Gharb (Maroc).*, Revue des Sciences de l'Eau ,Volume 32, 2019
- [2] Paul DIXNEUF : *Analyse de la performance de la méthode d'imputation de données manquantes missForest et application à des données environnementales*, ÉCOLE DE TECHNOLOGIE SUPÉRIEURE, UNIVERSITÉ DU QUÉBEC, 2019
- [3] Elizabeth Ann Maharaj, Pierpaolo D'Urso, Jorge Caiado : *Time Series Clustering and Classification*, CRC Press, 2019
- [4] K. Dion, M. Slivitzky, M. Saïd et A.-C. Favre : *Analyses des ruptures et des tendances dans les écoulements annuels observés et simulés par le MRCC en climat actuel (1961-1999) pour les 21 bassins versants de la péninsule Québec/Labrador*, Rapport de recherche No R1069, INRS-Eau, Terre et Environnement, 2009
- [5] Anil Jadhav, Dhanya Pramod Krishnan Ramanathan : *Comparison of Performance of Data Imputation Methods for Numeric Dataset*, Applied Artificial Intelligence, 2019